

Heterojen Federe Öğrenmede Dürüst İstemci Dışlama ve Uzlaşma Testinin Sınırları

Sebahattin Gökçen Özden ve Kadir Sarıkaya

Özet—Federe öğrenmede sonucu tarafı savunmalar, hangi istemci güncellemelerinin kabul edileceğine karar verir. İstemci verileri heterojen olduğunda dürüst güncellemeler de olağan dışı görünebilir; bu yüzden bir savunma, hiç saldırgan yokken bile dürüst istemcileri reddedebilir. Bu maliyeti, sekiz sonucu tarafı kuralın dört veri kümesi, üç heterojenlik düzeyi (Dirichlet $\alpha = 0.5, 0.1, 0.01$) ve beş saldırı ailesi üzerinde tamamlanmış bir değerlendirmesinde ölçüyoruz; değerlendirme 2 125 tamamlanmış koşum ve kayda geçmiş beş başarısız koşumdan oluşur. Saldırgan yokken Multi-Krum dokuz temiz koşulun hepsinde dürüst gönderimlerin %32.2'sini, FLAME %42.4–48.9'unu, bileşik filtre Fed-MDBSCAN-G ise $\alpha = 0.01$ koşulunda %42.6'ya kadarını dışlar; son doğruluk, düz ortalamaya göre 65.55 yüzde puana kadar düşer. İlk iki kuralda dışlama, kuralın kaç güncelleme tuttuğundan kaynaklanır: Multi-Krum yapılandırılmaz her turda 90 güncellemenin 61'ini tutar; FLAME ise 990 temiz turun 719'unda izin verilen en küçük çoğunluğu (90'da 46) tutmuştur. Uzaklık kısıtlı bir saldırı altında Multi-Krum altı koşulun beşinde yalnız dürüst istemcileri reddetmiştir. Fed-MDBSCAN-G için, küme doğrulama aşamasının ilk kabul edilen güncellemelerden oluşan hiçbir grubu reddedemeyeceği basit bir geometrik koşul türetiyoruz. Bu koşul kayıtlı 36 saldırılı kontrol noktasının 35'inde sağlanmıştır; testi daha önce test edilmeyen güncellemelere genişletmek ise dürüst ret eklemiş, saldırgan reddi eklememiştir. Bu bulgular geometrik savunmaların genel olarak değil, değerlendirilen uygulamaların başarısızlıklarını açıklar. Saldırgansız dürüst istemci dışlamasının ve doğruluk kaybının, saldırı tespiti ve saldırı başarısıyla birlikte raporlanmasını öneriyoruz.

Anahtar Kelimeler—Federe öğrenme, zehirleme, dayanıklı birleştirme, veri heterojenliği, yanlış pozitifler, kümeleme tabanlı savunmalar.

I. GİRİŞ

FEDERE öğrenme, istemcilerin eğitim örneklerini sunucuda toplamadan, yerelde hesaplanan güncellemelerden ortak bir model eğitir [1]. Aynı ayırım, kötü niyetli istemcilerin zehirlenmiş güncellemeler (poisoned updates) göndermesine ya da manipüle edilmiş verilerle eğitim yapmasına da olanak tanır [2], [3], [4]. Sonucu tarafı savunmalar buna dayanıklı birleştirme (robust aggregation), güncelleme filtreleme (update filtering) veya güvenilir bir referansa (trusted reference) karşı doğrulama ile karşılık verir [5], [6], [7], [8].

Bu belge, İngilizce gönderim sürümünün yazarlar için hazırlanmış Türkçe çalışma çevirisidir; dergiye gönderilecek metin İngilizce sürümdür. Sayılar İngilizce sürümle birebir karşılaştırılabilir diye ondalık ayrıcı olarak nokta kullanılmıştır.

S. G. Özden, Bilgisayar Mühendisliği Bölümü, Mühendislik ve Mimarlık Fakültesi, Tokat Gaziosmanpaşa Üniversitesi, Tokat, Türkiye (e-posta: bygokcen@gmail.com).

K. Sarıkaya, Endüstri Mühendisliği Bölümü, Mühendislik ve Mimarlık Fakültesi, Tokat Gaziosmanpaşa Üniversitesi, Tokat, Türkiye.

Sorumlu yazar: Sebahattin Gökçen Özden.

Bir filtreleme savunması iki ayrı soruyu yanıtlamak zorundadır: saldırganları dışlıyor mu ve yararlı dürüst katkıları (honest contributions) koruyor mu? İstatistiksel heterojenlik her ikisini de zorlaştırır. Dürüst istemciler turun merkezî eğiliminden uzak güncellemeler üretebilirken, koordineli saldırılar dürüst dağılıma yakın kalabilir [9], [10]. Önceki değerlendirmeler bu koşullarda yanlış pozitifleri (false positives), fayda kaybını ve arka kapı (backdoor) açıklarını belgelemiştir [11], [12], [13]. Bunun değerlendirme açısından iki sonucu vardır. Savunmalar hiç saldırgan yokken de ölçülmeli, bileşik bir savunmanın yalnız uçtan uca sonucu değil, içindeki tek tek kararlar da incelenmelidir.

Bu soruları, sekiz sonucu tarafı kuralın tamamlanmış bir değerlendirmesi ve Fed-MDBSCAN-G adlı bileşik filtrenin (composite filter) ayrıntılı analiziyle inceliyoruz. Fed-MDBSCAN-G, geometrik medyan tabanlı bir kabul bölgesini (geometric-median acceptance region), göreceli yoğunluk bölümlenmesini (relative-density partitioning) ve paylaşılan komşu küme doğrulamasını (shared-neighbour cluster validation) birleştirir. Amacımız açıklayıcıdır. Bu değerlendirmede gözlenen maliyetleri ve başarısızlıkları açıklamaya çalışıyoruz; bileşik yöntemi genel olarak üstün bir savunma olarak sunmuyor, bulguların geometrik filtrelemenin başarabileceklerini tükettiğini de iddia etmiyoruz.

İlk katkımız, $\alpha \in \{0.5, 0.1, 0.01\}$ Dirichlet yoğunlaşma (Dirichlet concentration) değerlerinde yapılan, veri kümesi kapsamı açıkça belirtilmiş ve dürüst istemci dışlamasını (honest-client exclusion) son doğrulukta değişimden ayıran saldırgansız (adversary-free) bir karşılaştırmadır. Bu ortamda sabit kardinaliteli seçim (fixed-cardinality selection) kesin bir dışlama oranı verir; çoğunluk kümesini tutma (majority-cluster retention) ise yalnızca bir üst sınır verir ve bu sınıra ulaşıp ulaşılmadığı ölçülmelidir. Bunu, kayıtlı FLAME kabul kümelerini doğrudan sayarak ölçüyoruz; küme boyutlarını yuvarlanmış ret oranlarından geri hesaplamıyoruz.

İkinci olarak, bileşik yöntemin karar yolunun (decision path) koşullu bir analizini veriyoruz. Küme içermeye (set containment) ilişkisi, sonraki aşamaların hangi ilk dışlamaları geri alamayacağını belirler. Dışbükeylik (convexity) ise her aday grup ilk kabul havuzunun (initial acceptance pool) içinde kaldığında küme merkezi doğrulamasının (centroid validation) etkisiz kalması için bir yeter koşul (sufficient condition) verir. Bu koşulu kayıtlı kontrol noktalarında (checkpoint) sınıyor ve varsayımlarının nerede sağlandığını raporluyoruz. Ayrı bir skor sıralaması sonucu, ret yapan bir kuralın ne zaman sıfır saldırgan yakalama oranı (recall) ve pozitif dürüst ret oranına sahip olacağını betimler. Bu sonuç açık bir sıralama öncülüne (ordering premise) dayanır; saldırıya getirilen bir uzaklık kısıtı

(distance constraint) bu öncülü her savunma skoru için tek başına garanti etmez.

Üçüncü olarak, sabit matrisler üzerindeki yeniden oynatmalar (replay), kümelenmemiş (unclustered) düşük yoğunluklu (low-density) güncellemelerin ele alınışında iki değişikliği sunar. Bu güncellemeleri tekil (singleton) olarak test etmek incelenen matrislerde saldırgan reddi eklemeyi; doğrudan dışlamak ise bir yama arka kapısı bloğunda farklı bir ödünleşim verir. Yeniden oynatmalar, test kapsamının (test coverage) eksikliği doğrulama kuralının kendi başarısızlığından ayırır. Bunlar kayıtlı durumlardaki kararlarla ilgilidir; yeniden eğitilmiş varyantların doğruluğu veya saldırı başarısıyla ilgili değildir.

Değerlendirme 2130 planlı kural–koşul–tohum biriminden (unit) oluşur ve bunların 2125'i tamamlanmıştır; beş başarısız birim hesapta tutulmaktadır. Analiz geriye dönük ve betimseldir. Katkısı, kontrollü gözlemleri açık karar kurallarına ve yeter koşullara bağlamaktır; yeni evrensel alt sınırlar ya da bir kuramın ileriye dönük doğrulanması değildir.

Bölüm II ilgili çalışmaları gözden geçirir, Bölüm III sistem modelini ve değerlendirilen bileşik yöntemi tanımlar. Bölüm IV koşullu analizi geliştirir, Bölüm V deney protokolünü açıklar. Bölüm VI ve Bölüm VII saldırganlı ve saldırganlı tur sonuçlarını raporlar. Bölüm VIII kayıtlı kontrol noktalarında karar yollarını analiz eder; Bölüm IX ve Bölüm X bulguları tartışır ve çalışmayı sonuçlandırır.

II. İLGİLİ ÇALIŞMALAR

A. Dayanıklı birleştirme ve heterojen veri

Komşuluk tabanlı seçim, koordinat bazında kestiriciler, geometrik medyan ile birleştirme ve güven önyüklemesi (trust bootstrapping), zehirlenmiş güncellemelerin etkisini farklı varsayımlar altında sınırlar [5], [6], [14], [7]. Heterojen veri için önceki analizler, belirtilen varsayımlar altında istatistiksel sınırlar ortaya koyar ve dayanıklı birleştirme yapıları önerir [15], [16]. Bizim sonuçlarımız farklı bir nicelikte, yani belirli bir turda hangi istemcilerin kabul edildiği ya da dışlandığıyla ilgilidir. Bölüm IV içindeki temel küme ve dışbükeylik argümanları optimizasyon hatası sınırlarının yerini tutmaz ve model doğruluğu için bir sınır da ima etmez.

FLAME kümeleme, kırpma ve gürültüyü birleştirir [8]. DeepSight model davranışını inceler ve kümelemeyi şüphe tahminleriyle birleştirir [17]; FLShield istemci tarafı doğrulamaya dayanır [18]; CrowdGuard ve MESAS birden fazla aşama veya istatistik kullanır [19], [20]; Fedward ve FLAC ise kümeleme tabanlı savunmaları daha da geliştirir [21], [22]. Bu tasarımlar neyi gözlemledikleri ve nasıl karar verdikleri bakımından farklı olduğundan, bir aşama için kanıtlanan cebirsel bir özellik varsayımları denetlenmeden diğerlerine aktarılamaz.

Burada incelenen bileşik yöntem, göreceli yoğunluk bölümlenmesini ve paylaşılan komşu kümelemesini MDBSCAN algoritmasından uyarlar [23]. Filtre olarak kullanımı, komşuluk kesmesi (neighbourhood cutoff) ve kümelenmemiş noktaları ele alışı özgün kümeleme algoritmasından farklıdır; değerlendirdiğimiz şey bu yerel uyarlamadır. Kabul kümesi içermeye argümanı, birleşik (conjunctive) kaskadların (cascade) bilinen bir özelliğidir [24]; burada önemli olan, kullanılan geri dönüş (fallback) mekanizmasının ilk havuza içerilmeyi koruyup

korunmadığıdır. Saldırı altında merkez tabanlı anomali tespiti üzerine yapılan çalışmalar, kabul bölgeleri ile saldırgan girdiler arasındaki etkileşim için ilgili bir bağlam sunar [25].

B. Yanlış pozitifler ve önceki değerlendirmeler

Adalet (fairness) çalışmaları, savunmaların istatistiksel olarak sıra dışı dürüst istemcileri nasıl dışladığını incelemiştir [11], [26], [27]. IID olmayan veri altında federe öğrenmeye ilişkin yakın tarihli değerlendirmeler de savunma başarımının kötüleştiğini belgeler [28], [12], [29]. Bellachia vd., saldırganların dağınık bir dürüst popülasyon içinde gizlenmesini açıkça betimler [13]; bu mekanizmayı onların çalışmasına atfediyoruz.

Şans köşegeninin (chance diagonal) altındaki çalışma noktaları (operating point) önceki çalışmalarda da görülür. Bellachia vd.'nin Tablo 8'i, IID olmayan bir IBA koşulunda FLAME için TPR = 0 ve FPR = 0.45 raporlar [13]. Ye vd.'nin Tablo V'inde Dir(0.1) için verilen TPR/TNR çiftleri, FoolsGold ve CrowdGuard için sırasıyla $J = -4.15$ ve -6.8 yüzde puan anlamına gelir [12]. Dolayısıyla negatif J , burada değerlendirilen uzaklık kısıtlı yoklamalara (probes) özgü değildir.

Farklı çalışmalardan gelen oranlar ortak bir sayısal doğrulama olarak okunmamalıdır. Örneğin Ye vd., FLAME için Dir(0.5) koşulunda %73.29, Dir(0.1) koşulunda %54.87 TNR raporlar; bunlar %26.71 ve %45.13 FPR değerlerine karşılık gelir. Bu saldırganlı tur oranları, bizim saldırganlı sonuçlarımızdan farklı kohort boyutlarına ve paydalara dayanır; bu nedenle yapılandırmamızın %48.89'luk üst sınırını ne doğrular ne de çürütür.

Değerlendirme yöntemi başlı başına bir araştırma konusudur. Shejwalkar vd. zehirleme tehdit modellerinin ne kadar gerçekçi olduğunu inceler [30]; Abad vd. ise arka kapı içermeyen kontrollerin rolünü tartışır [31]. Heterojenliği gözetken yakın tarihli bir tarama da savunma değerlendirmelerinin dürüst non-IID istemcilere karşı yanlış pozitifleri ve dürüst istemci dışlamasını raporlaması gerektiğini savunur [32]. Bizim katkımız saldırganlı kontrollerin, karar yolu ölçümlerinin ve tek bir bileşik yöntemin koşullu analizinin yeniden üretilebilir bir birleşimidir. Ne dürüst kontroller ne de negatif J gözlemi için öncelik iddia ediyoruz.

III. SİSTEM MODELİ VE KARAR KURALLARI

A. Protokol ve tehdit modeli

r turunda i istemcisi w_r modelini alır ve yerel model farkı (local model delta) $u_{r,i} = w_{r,i}^{\text{local}} - w_r$ güncellemesini gönderir. B_r indekslerini kabul eden düz ortalama (uniform mean) filtresi $w_{r+1} = w_r + |B_r|^{-1} \sum_{i \in B_r} u_{r,i}$ güncellemesini uygular. Paneldeki diğer kurallar kendi ağırlıklandırma, kırpma veya koordinat bazında birleştirme yöntemlerini kullanır; düz ve örnek ağırlıklı ortalama (sample-weighted mean) ayrı referans yöntemler olarak yer alır.

Sunucu güvenilirdir ve istemci kimlikleri sabittir. Saldırganlar kendi eğitim verilerini veya gönderdikleri güncellemeleri kontrol eder. Min-Max ve Min-Sum yoklamaları her şeyi bilen (omniscient) türdendir; mevcut dürüst güncellemeleri de gözlemler ve ilgili uzaklık sınırına uyan ortak bir kötü niyetli

vektör oluştururlar. Gerçek kötü niyetli kimlikler bu saldırıları oluşturmak ve kararları puanlamak için kullanılır; savunmaya hiçbir zaman girdi olarak verilmez.

$U = \{1, \dots, n\}$ gönderimleri (submission) indekslesin; H ve A da U kümesini dürüst ve saldırgan katılımcılara ayırsın. $|H| > 0$ olsun. Kabul edilen B indeksleri için $FPR = |H \setminus B|/|H|$ ve $|A| > 0$ olduğunda $TPR = |A \setminus B|/|A|$ tanımlanır. Bunların farkı Youden indeksi (Youden's index) $J = TPR - FPR$ ile verilir. Saldırgansız turlarda FPR değerine dürüst istemci dışlama oranı (benign exclusion rate, BER) diyoruz. Bu nicelikler katılım kararlarını betimler; doğruluğu veya arka kapı başarısını betimlemez.

Tanım 1 (Skor sıralı kural / Score-order rule): Gerçek s_i skorları verildiğinde, skor sıralı bir kural en yüksek skorlu k gönderimi veya belirli bir eşik için $s_i > \rho$ olanları atar. Eşit skorlar için belirli bir seçim kuralı tanımlanmalıdır. Radyal uzaklık ve en yakın komşu (nearest neighbour) uzaklık toplamları bu tür skorlara örnektir. Bölüm IV içindeki teorem, farklı skorların aynı sıralamayı ürettiğini varsaymaz. Küme üyeliği ikili bir skor olarak kodlanabilir; ancak bu kodlama, skorun uzaklık kısıtlı bir saldırıyla ilişkisi hakkında ek bir şey söylemez.

Tanım 2 (Monoton kaskad / Monotone cascade): Her ara kabul kümesi bir öncekinin altkümesiye kaskad monotondur. Daha önce çıkarılmış indeksleri geri kabul eden bir geri dönüş mekanizması bu özelliği bozabilir.

B. Değerlendirilen bileşik yöntem

Fed-MDBSCAN-G yönteminin ilk filtresi (initial filter) şu kümeyi kabul eder:

$$B_0 = \{i : \|u_i - m\|_2 \leq \rho \text{ median}_j \|u_j - m\|_2\}, \quad \rho = 2.5, \quad (1)$$

burada m , geometrik medyanın Weiszfeld yaklaşımıdır. Gönderimlerin yarısından azı kalırsa ilk havuz U olarak sıfırlanır.

$k' = \min(5, n-1)$ için yoğunluk, k' en yakın komşuya olan uzaklıkların toplamı d_i üzerinden hesaplanır. Yerel uygulama $d_i > 0$ olduğunda $k'/\max(d_i, 10^{-15})$, $d_i = 0$ olduğunda 1 döndürür; tek elemanlı girdi de 1 döndürür. Kullanılan kapı (deployed gate), boşluk eşiği 10 olan bir yoğunluk boşluğu göstergesi (density-gap indicator) en az $\max(2, \lceil 0.05n \rceil)$ ilk retle birlikte gerçekleştiğinde açılır. Üç turluk bir bellek, daha önceki bir etkinleşmeden sonra küme aşamasını (cluster stage) temiz turlarda sönümlenmek kaydıyla etkin tutabilir.

Küme aşaması etkin olduğunda bütün gönderim kümesini yoğunluğa göre bölümler ve düşük yoğunluklu L altkümeleri üzerinde paylaşılan komşu kümelemesi çalıştırır. Bulunan her S grubu şu koşulda reddedilir:

$$\|c_S - m_{B_0}\|_2 > \tau R_0, \quad R_0 = \max(10^{-10}, \text{median}_{j \in B_0} \|u_j - m_{B_0}\|_2), \quad (2)$$

burada c_S grubun aritmetik merkezi (arithmetic centroid), m_{B_0} ise B_0 kümesinin geometrik medyanıdır ve $\tau = 2$ alınır. Bulunan bir gruba atanmamış noktalar bu aşamada test edilmez. Aday gruplar $L \cap B_0$ kümesinden değil L kümesinden oluşturulduğu için B_0 dışındaki indeksleri içerebilir.

Birleşik küme, reddedilen grupların üyelerini B_0 kümesinden çıkarır. Ardından gönderimlerin yarısından azı kalırsa bir

valf (safety valve) B_0 kümesini geri yükler. Bu nedenle tam yol monoton bir kaskad olmak zorunda değildir; ancak son çıktı her zaman $B \subseteq B_0$ koşulunu sağlar ve aşağıdaki ilk dışlama sonucunun gerektirdiği yalnızca budur.

IV. KOŞULLU ANALİZ

Bu bölümdeki önermeler tek bir tura ve az önce tanımlanan karar kurallarına ilişkindir. Yalnızca küme içermek, kardinalite ve dışbükeyliğe dayandıkları için ampirik geçerlilikleri, varsayımlarının uygulanan yolda sağlanıp sağlanmadığına bağlıdır; Bölüm VIII bunu kayıtlı kontrol noktalarında denetler.

A. Kabul kümesi içermek ve kardinalite

Önerme 1 (İlk dışlama tabanı / Initial exclusion floor): $B \subseteq B_0$ ise $FPR(B) \geq FPR(B_0)$ olur ve $|A| > 0$ için $TPR(B) \geq TPR(B_0)$ sağlanır. Bu, monoton bir kaskad ve en fazla B_0 kümesini geri yükleyen bir geri dönüş mekanizması için geçerlidir.

İspat: $H \setminus B_0 \subseteq H \setminus B$ ve $A \setminus B_0 \subseteq A \setminus B$ içermeleri, ilgili popülasyon boyutlarına bölündükten sonra eşitsizlikleri verir. ■

Dolayısıyla sonraki aşamalar, ilk filtrenin dışladığı dürüst bir istemciyi geri kabul edemez. Yine de çalışma noktasını iyileştirebilirler; örneğin ek dürüst istemci reddetmeden ek saldırganları reddedebilirler. Bu yüzden önerme bir Pareto iyileşmesini dışlamaz.

Sonuç 1 (Sabit kardinaliteli seçim / Fixed-cardinality selection): n gönderimin tam olarak m tanesi kabul ediliyorsa saldırgansız bir turda $BER = 1 - m/n$ olur. a saldırgan ve reddedilen t saldırgan varken, $n > a$ koşuluyla $FPR = (n - m - t)/(n - a)$ olur.

İspat: Toplam $n - m$ ret vardır; bunların t tanesi saldırgan, $n - m - t$ tanesi dürüştür. ■

Multi-Krum yapılandırılmamız $f = \lceil 0.3n \rceil$ ve $m = n - f - 2$ kullanır. $n = 90$ iken 61 güncelleme tutar; bu yüzden temiz BER değeri 29/90 olur. $a = 27$ ve $t = 0$ iken saldırlı turdaki FPR değeri 29/63 olur. Bu özdeşliklerle uyum yalnızca seçim kardinalitesini doğrular (Bölüm V-C).

Sonuç 2 (Çoğunluk kümesini tutma / Majority-cluster retention): Saldırgansız bir turda, boyutu $c \geq c_{\min}$ olan tek bir kümeyi tutan kural için $BER = (n - c)/n \leq (n - c_{\min})/n$ olur. Eşitlik ancak ve ancak $c = c_{\min}$ olduğunda sağlanır. a saldırgan ve t saldırgan reddiyle $FPR = (n - c - t)/(n - a)$ olur.

İspat: Küme dışında kalan reddedilmiş indeksleri sayın ve saldırgan retlerini çıkarın. ■

Yerel FLAME yolu $n = 90$ iken $c_{\min} = \lfloor n/2 \rfloor + 1 = 46$ kullanır; bu da 44/90 değerinde temiz bir üst sınır verir. Heterojenlik tek başına eşitliği zorunlu kılmaz. Kümelemenin başarısız olduğu veya geri dönüş mekanizmasının devreye girdiği turlar, fiilen yürütülen yola göre ele alınmalıdır.

B. Küme merkezi doğrulaması

Önerme 2 (Dışbükey zarf yarıçap sınırı / Convex-hull radius bound): Boş olmayan bir S grubu, güncellemelerinin herhangi

bir dışbükey birleşimi (convex combination) $g(S)$ ve herhangi bir m_0 referansı için

$$\|g(S) - m_0\| \leq \max_{i \in S} \|u_i - m_0\|$$

sağlanır. s üyenin düz ortalaması için, bir üyenin yarıçapı en fazla r_a , diğerlerinin en fazla r_b ise

$$\|c_S - m_0\| \leq \frac{r_a + (s-1)r_b}{s}$$

olur.

İspat: $g(S) - m_0$ ifadesini $u_i - m_0$ vektörlerinin dışbükey birleşimi olarak yazın ve üçgen eşitsizliğini uygulayın. İkinci ifade $1/s$ ağırlıklarını kullanır. ■

Buna göre bir grup merkezi bir topun dışındaysa en az bir üye de dışındadır. Bu ifade tek tek üyelere değil gruba ilişkindir. Bütün bir grubu reddetmek topun içindeki üyeleri de dışlayabilir: gerçel doğru üzerinde merkez 0 ve yarıçap 2 iken $\{1, 5\}$ grubunun merkezi 3'tür; üyesi 1 topun içinde olduğu hâlde grup reddedilir. Tersine, sapmalar birbirini götürerek bir üye dışarıdayken merkezi topun içine yerleştirebilir. İlk filtre ve uzlaşma filtresi (consensus filter) de farklı referans noktaları ve yarıçaplar kullanır; bu nedenle sınır, bu iki filtrenin istemci düzeyindeki kararlarını sıralamaz.

Önerme 3 (Küme merkezi doğrulamasının etkisiz kalması için yeter koşul / Sufficient condition for inactive centroid validation): Boş olmayan B_0 için

$$\Gamma(B_0) = \frac{\max_{i \in B_0} \|u_i - m_{B_0}\|_2}{R_0}$$

tanımlansın; burada R_0 , (2) içindeki tabanlı yarıçaptır (floored radius). $\Gamma(B_0) \leq \tau$ ise boş olmayan hiçbir $S \subseteq B_0$ grubu (2) ile reddedilmez. Test edilen her grup böyle bir altkümeysen ve başka hiçbir aşama üye çıkarmıyorsa son kabul kümesi $B = B_0$ olur.

İspat: B_0 kümesinin her üyesi m_{B_0} merkezli, τR_0 yarıçaplı kapalı topun içindedir. Top dışbükey olduğundan bir $S \subseteq B_0$ altkümesinin üyelerinin her dışbükey birleşimi topun içindedir ve kesin ret eşitsizliği sağlanamaz. ■

Koşul yeterlidir ama gerekli değildir. Ayrıca aday grupları B_0 dışındaki üyeleri içerebilen bileşik yöntemimiz için genel olarak geçerli değildir. Örneğin $B_0 = \{-1, 1\}$ için $\Gamma = 1$ olur; ama $\{1, 10\}$ grubunun merkezi 5.5 olduğundan grup yarıçap-2 testini geçemez. Bu yüzden önermeyi kayıtlı matrislere uygulamadan önce altküme koşulunu doğruluyoruz.

C. Yoğunluk sıralaması ve uygulama sınırı

Önerme 4 (Ayrılcı eşikle yoğunluk ayrımı / Density separation with a separating threshold): Uzaklık toplamalarının kesinlikle pozitif olduğu ideal $\text{rd}(i) = k'/d_i$ skorunu ele alalım. $|A| \geq k' + 1$ olsun; bütün saldırgan çiftleri arasındaki uzaklıklar en fazla $\delta_A > 0$ ve her dürüst noktanın ortalama k' -en yakın komşu uzaklığı en az $\delta_H > \delta_A$ olsun. O zaman

$$\min_{a \in A} \text{rd}(a) \geq 1/\delta_A > 1/\delta_H \geq \max_{i \in H} \text{rd}(i)$$

olur. $\max_{i \in H} \text{rd}(i) < t \leq \min_{a \in A} \text{rd}(a)$ koşulunu sağlayan bir eşik için $L = \{i : \text{rd}(i) < t\}$ kümesi bütün dürüst noktaları içerir ve hiçbir saldırgan noktayı içermez.

İspat: Her saldırganın δ_A uzaklık içinde k' başka saldırganı vardır; bu nedenle en yakın komşu uzaklık toplamı en fazla $k'\delta_A$ olur. Varsayılan dürüst ortalama uzaklık $d_i \geq k'\delta_H$ verir. Terslerini almak sıralamayı, eşik koşulu da seçilen kümeyi verir. ■

Eşik kısıtı zorunludur, çünkü bütün skorların üzerindeki bir eşik saldırganları da seçer. Önerme, yerel uygulamadaki tam kopyalara (exact duplicates) da doğrudan uygulanmaz. Etkin en yakın komşu uzaklıklarının toplamı sıfır olduğunda kod $\text{rd} = 1$ döndürür; $k' = 1$ ile tek boyutlu $[0, 0, 0.1, 0.2]$ girdisi için gerçek çıktı $[1, 1, 10, 10]$ olur. Bu davranışı çalışma kaynağında ve iki dondurulmuş (frozen) kopyada yeniden ürettik. Dolayısıyla tam kopyalama tek başına Önerme 4 içindeki yüksek yoğunluk sıralamasını üretmez. Kümeleme sezgisi önceki gözlemlerle uyumludur [13]; ancak belirli bir koşumu (run) açıklamak, o koşumda hesaplanan skorları ve yönlendirme (routing) kararlarını gerektirir.

D. Koşullu bir skor sıralaması sonucu

Teorem 1 (Yalnız dürüst ret / Honest-only rejection): H ve A boş olmasın ve $1 \leq k \leq |H|$ olsun. Bir kural en yüksek k skoru atıyorsa ve $s_{(k)}^H$ en büyük k 'nci dürüst skor olmak üzere $\max_{a \in A} s_a < s_{(k)}^H$ ise

$$\text{TPR} = 0, \quad \text{FPR} = k/|H|, \quad J = -k/|H|$$

olur. Eşik kuralı için, $\rho \geq \max_{a \in A} s_a$ ise aynı sonuç $k = |\{i \in H : s_i > \rho\}| > 0$ ile geçerlidir.

İspat: Kesin sıralama, atılan k indeksin hepsini H içine yerleştirir. Eşik durumunda hiçbir saldırgan eşiği aşmaz. Dürüst ve saldırgan retlerini sayın. ■

Teorem koşullu bir sayma sonucudur. Min-Max ve Min-Sum uzaklıkları kısıtlar [10], ancak bu kısıtlar teoremin sıralama öncülünü her skor için sağlamaz. Örneğin $\{-2, 0, 0.1, 2\}$ dürüst noktalarının en büyük ikili uzaklığı 4'tür ve -1 noktası her birine en fazla 3 uzaklıktadır; yine de dürüst geometrik medyana en uzak üç noktayı reddeden bir kural, -2 ve 2 ile birlikte -1 noktasını da reddeder. Negatif J ayrıca model doğruluğu veya saldırı başarısı hakkında doğrudan bir şey söylemez. Ret bütçesini büyütme J değerini ancak yalnız dürüst sıralaması korunduğu sürece daha negatif yapar.

Ne içirme ne de dışbükeylik sonucu referans noktasının nasıl elde edildiğine bağlıdır; bu nedenle ikisi de güvenilir sonucu verisi kullanan kurallara uygulanır. FLTrust'ın Bölüm VII içinde elde ettiği pozitif aile ortalaması J ampirik bir gözlemdir; dış bir referansın dayanıklılık (robustness) için gerekli ya da yeterli olduğunu göstermez.

V. DENEY PROTOKOLÜ

A. Veri, eğitim ve kapsam

Arşivlenmiş matris 149 iş ve MNIST [33], Fashion-MNIST [34], UCI HAR [35] ve CIFAR-10 [36] üzerinde 2 130 planlı kural-köşül-tohum biriminden oluşur. MNIST ve Fashion için 784–200–10 çok katmanlı algılayıcı kullanılır; HAR için genişlikler 561–128–64–6'dır ve 0.2 dropout uygulanır; CIFAR için 32 ve 64 kanallı iki evrişim katmanının ardından 256 ve 10 genişliğinde tam bağlantılı katmanlar kullanılır. Ana

Tablo I

BLOKLARA GÖRE PLANLANAN DEĞERLENDİRME KAPSAMI. BİR BİRİM, BİR KURAL-KOŞUL-TOHUM KOŞUMUDUR. PLANLANAN 2130 BİRİMİN 2125'İ TAMAMLANMIŞ, 5'İ DOLDURULMAK YA DA YENİ TOHUMLA TEKRARLANMAK YERİNE BAŞARISIZ OLARAK TUTULMUŞTUR. BLOKLAR DENGELİ BİR TAM FAKTÖRİYEL TASARIM OLUŞTURMAZ.

Blok	Birim
Ana matris (saldırılı ve saldırganlı)	1500
Ablasyon varyantları	252
Eşleşen saldırısı kapatılmış kontroller	156
Kâhin (oracle) tanıları	78
Alternatif bölümler politikası	54
Sabit yerel adım kontrolü	54
Saldırı başlangıç/bitiş zamanlaması	36
Planlanan toplam	2130

yapılandırmalarda 100 istemci, turda 90 katılımcı, 30 tur, 42, 137 ve 2024 rastgelelik tohumları (seed), 32 batch boyutu, üç yerel epok, 0.01 öğrenme oranı ve 0.9 momentum kullanılır.

Dirichlet yoğunlaşma parametresi 0.5, 0.1 ve 0.01 değerlerini alır [37]. En az örnek sayısı onarımı (minimum-count repair) her istemciye en az 20 örnek ayırır; bu nedenle son bölümler dokunulmamış bir Dirichlet çekilişi değildir. Üç veri kümesi 17 koşullu ortak bir ana bloğu paylaşır, CIFAR'ın kapsamı ise daha dardır; kalan bloklar Tablo I içinde listelenmiştir. Dört örnek ağırlıklı HAR koşumu ve Min-Max altında bir CIFAR FLAME koşumu başarısız olmuştur. Bunlar başarısız olarak tutulmuş; ne doldurulmuş ne de tanılama amaçlı yeniden koşumlarla değiştirilmiştir.

Bu makaledeki bütün analizler mevcut sonuçları kullanır. Bölüm IV içindeki koşullu argümanlar ve birkaç kontrol noktası analizi, sonuçlar incelendikten sonra geliştirilmiştir. İçerik özetleri (hash) kanıt dosyalarını tanımlar; ancak önkayıd veya hipotezlerin hangi sırayla kurulduğunu kanıtlamaz.

B. Kontrol blokları ve saldırılar

Saldırganlı ana koşullar, üç yoğunlaşma değerinin her birinde sıfır kötü niyetli istemciyle yapılandırılmıştır; CIFAR için $\alpha = 0.5$ kontrol hücresi (cell) yoktur. Ayrı saldırısı kapatılmış kontroller (attack-disabled controls), saldırılı yapılandırmaların istemci kimliklerini ve takvimlerini korur ama saldırıyı devre dışı bırakır; yama arka kapısı karşılaştırmasında kontrol işlevi görür.

Saldırı aileleri şunlardır: yüksek Gauss gürültüsü (koordinat standart sapması 5), etiket çevirme (label flipping), sağ alt köşede 3×3 beyaz yama arka kapısı (hedef sınıf 0, zehirleme oranı 0.2), sınırlı rastgele pertürbasyonlar (bounded random perturbations) ve kısıtlı her şeyi bilen yoklamalar (constrained omniscient probes). Sınırlı aile, 0.005 görelî ölçekli bir yön yoklamasını ve 0.3 görelî ölçekli, eski `adaptive_gaussian` tanımlayıcısını içerir; adına rağmen ikincisi optimize edilmiş, savunmaya uyarlanmış bir saldırı değil, sınırlı rastgele gürültüdür. Kısıtlı yoklamalar dürüst ortalamasının tersi yönünde ortak bir doğrultu kullanır ve bunu bir

Min-Max veya Min-Sum sınırını sağlayacak biçimde ölçekler. Bunlar tanımlanmış yapılarıdır, kapsamlı bir saldırı araması değildir. Aile etiketleri ölçülmüş bir radyal yer değiştirmeyi kodlamaz ve koşul kapsamı aileler arasında farklıdır.

C. Uygulamalar ve sadakat sınırları

Panel şunlardan oluşur: düz ortalama, örnek ağırlıklı ortalama, norm kırpm, koordinat bazında medyan, $f = \lceil 0.3n \rceil$ ve $m = n - f - 2$ ile Multi-Krum, 100 kök örnekle (root examples) normalize FLTrust, 0.001 gürültü düzeyli yerel HDBSCAN tabanlı FLAME ve Fed-MDBSCAN-G. Yedi ablasyon (ablation) varyantı ayrıca değerlendirilir. Multi-Krum parametreleri ve her yöntemin eğitim protokolü yerel uygulama tercihleridir ve bu şekilde raporlanır.

Sınırlı bir FLTrust kontrolü, yerel birleştirme kuralını yazarların tanıtım kodundaki kuralın bir aktarımıyla 18 kayıtlı matris ve dört kök yapısı üzerinde karşılaştırmıştır; bu girdilerde birleşik güncellenmenin görelî farkı 2.8×10^{-7} değerinin altındadır. Dejenere kök ve sıfır güven yolları ayrışır. 5490 kanonik turda kök normları (root norms) kaydedilmemiştir; bu nedenle bütün gönderimlerin kabul edildiği 135 turda işaretlenmemiş bir dejenere kök yolu dışlanamaz. Kök ve istemci yerel iterasyon sayıları da farklıdır. Bu nedenle kontrol, tam eğitim protokolünün sadakatini (fidelity) kanıtlamaz.

Altı küçük FLAME kontrolü, sunucunun birleştirme yolu üzerinden kırpm, ortalama alma ve gürültü ölçeklemeyi sınar. HDBSCAN kümelemesinin yazarların uygulamasıyla eşdeğerliği ve özgün gürültü kalibrasyonu doğrulanmamıştır. Tamamlanmış 200 FLAME koşumu, işaretlenmiş hiçbir geri dönüş içermeyen 6000 tur kapsar. Bu analiz için kaydedilmiş kabul kimliklerini saydık ve katılımcı kimlikleri, karışıklık sayımları (confusion counts) ve dondurulmuş seçim koduyla karşılaştırdık. Tutulan küme bu turların her birinde 90'dan az üyeye sahiptir; dondurulmuş atlama yolları her katılımcıyı kabul ettiği için bu turların hiçbirisi o yolları izlememiştir. Geçmiş HDBSCAN etiketleri kaydedilmemiştir. Yeni ölçüm kodu gelecekteki koşumlar için etiketlerden türetilen küme boyutlarını kaydeder; ancak kanonik arşive geriye dönük olarak etiket ekleyemez.

Gözlenen bir sayımın cebirsel bir özdeşlikle uyuşması bu sınırları ortadan kaldırmaz. Yanlış 61 güncellemeyi tutan bir kural da temiz bir turda $BER = 29/90$ verir; bu yüzden kardinalite uyumu, skorların veya seçilen kimliklerin özgün uygulamayı yeniden ürettiğinin kanıtı değildir.

D. Ölçütler ve raporlama

Dürüst fayda kaybı (benign utility cost), aynı saldırganlı koşulda düz ortalamasının son doğruluğundan savunmanın son doğruluğunun çıkarılmasıyla bulunur; saldırı altında fayda kazancı (utility benefit) bu çıkarmayı tersine çevirir. Farklar yüzde puan (yp) olarak verilir. Doğruluk karşılaştırmaları mevcut tamamlanmış tohumları kullanır; bu nedenle eksik bir hücre tam eşleştirilmiş üç tohumlu bir karşılaştırma değildir. Ayrıca saldırgan yakalama oranını, dürüst reddi, J değerini ve tetiklenmiş hedef dışı örneklerdeki (triggered non-target examples) saldırı başarı oranını (attack success rate, ASR) raporluyoruz. FLTrust güvenli pozitif olmayan gönderimlere

sıfır ağırlık atar ve yerel kayıtlar bunları ret olarak sayar. Bu yüzden FLTrust'ın BER, FPR ve TPR sütunları, Multi-Krum veya FLAME'dekine benzer açık bir ret aşamasını değil, sıfır ağırlık kararlarını ölçer.

Bütün sonuçlar betimseldir. İstemci-tur gözlemleri birbiriyle ilişkilidir ve bağımsız deney tekrarları değildir. Üç tohum ve eşit olmayan kapsam nedeniyle hiçbir savunma için istatistiksel anlamlılık, eşdeğerlik veya genel üstünlük iddiasında bulunmuyoruz. Alarm özgüllüğü (specificity) yalnızca bileşik yöntem, yani panelde tur düzeyinde alarm üreten tek kural için raporlanır.

VI. SALDIRGANSIZ DIŞLAMA VE FAYDA

Tablo II, her tamamlanmış temiz hücre için 8100 dürüst istemci-tur gönderimine dayanır. Multi-Krum, mevcut dokuz hücrenin hepsinde (üç veri kümesi ve üç yoğunlaşma değeri; CIFAR hücresi yok) Sonuç 1 gereği $BER = 32.22\%$ verir.

Tablo IV içindeki doğrudan FLAME sayımları, çoğunluk kümesi sınırını bu sınıra ulaşılıp ulaşılmamasından ayırır. 11 temiz hücre ve 990 turda tutulan küme 719 turda (72.63%) tam olarak 46 üyedir. En küçük boyuta MNIST ve Fashion için $\alpha = 0.5$ koşulunda 90 turun 89'unda ulaşılırken, Fashion için $\alpha = 0.01$ ve HAR için $\alpha = 0.1$ ile 0.01 koşullarında turların yarısından azında ulaşılır. HAR için $\alpha = 0.01$ koşulunda yalnızca 9 turda ulaşılır ve ortalama tutulan boyut 51.83 'tür. Sınıra çoğu zaman ulaşılır; ancak bu sabit bir dışlama oranı değildir ve heterojenlik onu zorunlu kılmaz.


Bileşik yöntemin temiz BER değeri $\alpha = 0.5$ koşulunda $0.27-2.07$ ile $\alpha = 0.01$ koşulunda $24.37-42.57$ arasında değişir. İlk eşik her turun medyan yarıçapıyla ölçeklendiği için kabul edilen oran bu dağılımın biçimini izler; temiz hücre değerleri de başka, saldırılı turlardaki FPR değerini sınırlamaz.

Dışlama, fayda kaybının kaynaklarından yalnızca biridir. Norm kırpmı ve koordinat bazında medyan hiçbir istemciyi reddetmez; yine de MNIST'te $\alpha = 0.01$ iken son doğrulukları düz ortalamanın 22.5 ve 64.4 yüzde puan altındadır. Raporlanan savunma hücreleri üzerinden ortalama maliyet üç yoğunlaşma değerinde 3.3 , 10.9 ve 27.5 puandır; en büyük değer 65.55 puandır (MNIST'te $\alpha = 0.01$ iken FLAME). Bu ortalamalar farklı veri kümesi kapsamalarını birleştirir; tek tek koşullar Tablo III içinde verilmiştir. Dolayısıyla yalnız kabul oranları dürüst faydayı değerlendirmek için yetersizdir.

$\alpha = 0.01$ iken bileşik yöntem her veri kümesinde 90 saldırganız turun hepsinde alarm üretir (Tablo V). $\alpha = 0.1$ iken oran üç veri kümesinde sıfır, HAR'da 98.9% 'dur. Bunların hepsi yanlış alarmdır (false alarm). Ölçülen temiz bloklarda düşük özgüllüğe işaret ederler; bir kullanım sıklığı veya ek saldırılı tur verisi olmadan alarmın öngörü değerini (predictive value) belirlemezler.

VII. SALDIRI ALTINDA AYIRT ETME

Aile ortalaması J , yüksek Gauss gürültüsü için $+68.6$ yüzde puandan kısıtlı yoklamalar için -16.1 yüzde puana kadar uzanır (Tablo VI); aradaki değerler etiket çevirme için $+45.0$, yama arka kapıları için $+1.8$ ve sınırlı pertürbasyonlar için $+0.4$ 'tür. Aileler saldırı yapısı, saldırı oranı, yoğunlaşma



Şekil 1. Saldırganız dışlama, mevcut veri kümesi hücreleri üzerinden ortalamıştır. Kapsam yoğunlaşma değerine ve yonteme göre değişir. FLTrust sıfır ağırlıklı gönderimleri sayar. FLAME sınırına her turda ulaşılması gerekmez; doğrudan boyutlar Tablo IV içindedir.

değeri ve veri kümesi kapsamı bakımından farklıdır; bu nedenle bu sıralama ölçülmüş bir yer değiştirme bağımlılığı değil, betimsel bir karşılaştırmadır.

Kısıtlı yoklama altındaki altı Multi-Krum hücresinin beşinde sayımlar $TP = 0$, $FP = 2610$, $TN = 3060$ ve $FN = 2430$ şeklindedir. Tam olarak 29×90 gönderim reddedilir ve hepsi dürüsttür; bu da $FPR = 29/63 = 46.03\%$ verir. Bu, Sonuç 1 ile sıfır saldırgan yakalamada elde edilen değerdir. $\alpha = 0.1$ koşulundaki HAR hücresinde saldırgan yakalama oranı pozitifdir ve $J = +36.68$ puandır; dolayısıyla orada yalnız dürüst ret koşulu sağlanmaz. Kısıtlı saldırganların hepsi aynı vektörü gönderdiği için sıfır yakalama, seçim sınırındaki eşitliklerin saldırganlar lehine bozulmasıyla da tutarlıdır; tek başına Teorem 1 içindeki kesin sıralama öncülünü kanıtlamaz.

FLAME, kısıtlı yoklama altındaki sekiz hücrenin altısında sıfır saldırgan yakalama oranına sahiptir ve FPR değeri 57.51 ile 68.11 arasındadır. 63 dürüst katılımcı varken 90 gönderimden en az 46'sını tutmak, hiçbir saldırgan reddedilmediğinde FPR değerini $44/63 = 69.84\%$ ile sınırlar. $\alpha = 0.1$ koşulundaki CIFAR hücresi, üçüncü koşumu başarısız olduğu için iki tamamlanmış tohuma dayanır. Bileşik yöntemin de birkaç hücrede saldırgan yakalama oranı düşük veya sıfırdır; valf dalının ilgili koşumlarda çalıştığını doğrulamadığımız için bu toplam oranları valfe bağlamıyoruz.

FLTrust'ın kısıtlı aile ortalaması J pozitifdir ($+35.6$ puan); diğer üç karar kuralının ortalamaları ise negatiftir. Bu, güvenilir veri sinyallerinin daha fazla incelenmesini gerektirir; ancak tek bir kök kümesi uygulaması bu sinyallerin gerekli ya da genel olarak üstün olduğunu gösteremez. FLTrust ayrıca temiz turlarda dürüst gönderimlerin $11.9-33.1$ 'ine sıfır ağırlık atar ve Bölüm V-C içindeki sadakat sınırlarına tabidir.

Tablo IX, bileşik yöntemin yama arka kapısı sonuçlarını saldırısı kapatılmış kontrollerle eşleştirir. MNIST'te $\alpha = 0.1$ iken saldırı altındaki doğruluk 93.97 , kontrolde 94.14 'tür; saldırı başarısı ise 99.99 'a ulaşır. Aynı yoğunlaşma değerinde Fashion ve CIFAR için saldırı başarısı 99.93 ve

Tablo II

DÜRÜST İSTEMCİ DIŞLAMA ORANI (BER, %): HIÇ SALDIRGAN YOKKEN REDDEDİLEN DÜRÜST İSTEMCİ-TUR GÖNDERİMLERİ. ÜÇ TOHUM, 30 TUR, TURDA 90 KATILIMCI (HÜCRE BAŞINA 8 100 DÜRÜST İSTEMCİ-TUR). CIFAR-10 İÇİN $\alpha = 0.5$ BLOĞU YOKTUR. TİRELER PLANLANAN KAPSAM DIŞINDAKİ KOŞULLARDIR.

Kural	$\alpha = 0.5$			$\alpha = 0.1$				$\alpha = 0.01$			
	MNIST	Fashion	HAR	MNIST	Fashion	HAR	CIFAR-10	MNIST	Fashion	HAR	CIFAR-10
Düz ortalama (savunmasız)	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
Örnek ağırlıklı ortalama (savunmasız)	0.0	0.0	0.0	0.0	0.0	0.0	—	0.0	0.0	0.0	—
Norm kırpm	0.0	0.0	0.0	0.0	0.0	0.0	—	0.0	0.0	0.0	—
Koordinat bazında medyan	0.0	0.0	0.0	0.0	0.0	0.0	—	0.0	0.0	0.0	—
Multi-Krum	32.2	32.2	32.2	32.2	32.2	32.2	—	32.2	32.2	32.2	—
FLTrust (normalize)	33.1	31.9	11.9	25.3	27.3	19.6	—	30.3	32.3	31.0	—
FLAME (HDBSCAN)	48.9	48.9	48.3	48.9	48.7	47.4	48.7	48.7	47.0	42.4	45.5
Fed-MDBSCAN-G (tam)	0.3	0.4	2.1	0.2	0.5	24.1	0.1	42.6	38.7	24.4	39.9

Multi-Krum'un BER değeri her hücrede $1 - m/n = 29/90 = 32.22\%$ olup veri kümesinden ve α değerinden bağımsızdır (Sonuç 1). FLAME'in temiz üst sınırı $1 - (\lfloor n/2 \rfloor + 1)/n = 44/90 = 48.89\%$ değeridir (Sonuç 2). FLTrust ayrı bir ret aşaması değil, sıfır ağırlıklı gönderimleri sayar. Norm kırpm ve koordinat bazında medyan istemci düzeyinde ret üretmez; bu yüzden onlar için BER = 0 tanım gereğidir ve dürüst maliyetleri Tablo III içinde görülür.

Tablo III

DÜRÜST FAYDA KAYBI (BUC, YÜZDE PUAN): SAVUNMASIZ DÜZ ORTALAMANIN SON TUR DOĞRULUĞU EKSI SAVUNMANINKİ; TABLO II İLE AYNI SALDIRGANSIZ KOŞULLAR. POZİTİF DEĞERLER DÜZ ORTALAMADAN DAHA DÜŞÜK SON DOĞRULUĞU GÖSTERİR.

Kural	$\alpha = 0.5$			$\alpha = 0.1$				$\alpha = 0.01$			
	MNIST	Fashion	HAR	MNIST	Fashion	HAR	CIFAR-10	MNIST	Fashion	HAR	CIFAR-10
Norm kırpm	+0.0	+0.0	+0.2	-0.0	-0.0	+2.2	—	+22.5	+13.3	+0.0	—
Koordinat bazında medyan	+0.6	+0.8	+9.8	+4.7	+5.1	+33.3	—	+64.4	+40.9	+23.8	—
Multi-Krum	+1.0	+1.3	+2.8	+4.6	+4.8	+29.2	—	+44.9	+33.6	+11.0	—
FLTrust (normalize)	+2.4	+2.5	+13.2	+3.3	+4.1	+29.2	—	+11.6	+5.1	+10.6	—
FLAME (HDBSCAN)	+1.7	+1.9	+19.6	+10.4	+6.7	+38.1	+15.5	+65.5	+45.9	+15.2	+15.6
Fed-MDBSCAN-G (tam)	+0.0	+0.0	+1.8	-0.0	+0.1	+26.8	+0.0	+59.2	+41.9	+10.4	+14.9

Üç tohum üzerinden betimsel ortalamalar. Tohum başına eşleştirilmiş farklar yaptı dosyalarında, özet aralıklar ek belgede verilmiştir. Hiçbir tekil değere anlamlılık iddiası eklenmemiştir.

Tablo IV

SALDIRGANSIZ ANA HÜCRELERDE, KAYDEDİLMİŞ KABUL KİMLİKLERİNDEN SAYILAN FLAME TUTULAN KÜME BOYUTLARI. HER SATIR ÜÇ TOHUM VE 90 TUR İÇERİR.

Veri kümesi	α	Ort. boyut	Aralık	Boyut 46
MNIST	0.5	46.01	46–47	89/90
MNIST	0.1	46.03	46–47	87/90
MNIST	0.01	46.17	46–49	77/90
Fashion	0.5	46.01	46–47	89/90
Fashion	0.1	46.19	46–50	81/90
Fashion	0.01	47.73	46–56	39/90
HAR	0.5	46.50	46–53	67/90
HAR	0.1	47.30	46–51	38/90
HAR	0.01	51.83	46–62	9/90
CIFAR-10	0.1	46.13	46–48	79/90
CIFAR-10	0.01	49.09	46–61	64/90

Dondurulmuş normal yol gürtülmü olmayan tek bir kümeyi tutar; geçmiş küme etiketleri kaydedilmemiştir. En küçük boyuta 990 turun 719'unda ulaşılır. Sayımlar BER değerinden geri hesaplanmamıştır.

Tablo V

TUR DÜZEYİNDE ALARM ÜRETEK TEK DEĞERLENDİRİLMİŞ KURALIN SALDIRGANSIZ ALARM ORANI. PAYDA SALDIRGANSIZ TURLARDIR. $\alpha = 0.01$ İKEN HER VERİ KÜMESİNDE HER TUR ALARM ÜRETİR. BU SAYIMLAR TEMİZ KONTROLLERDEKİ YANLIŞ ALARMLARI ÖLÇER; BELİRLİ BİR SALDIRI SIKLIĞINDAKİ ÖNGÖRÜ DEĞERİNİ ÖLÇMEZ.

α	Veri kümesi	Alarm veren tur	Oran (%)	BER (%)
0.5	MNIST	0/90	0.0	0.27
0.5	Fashion	0/90	0.0	0.41
0.5	HAR	19/90	21.1	2.07
0.1	MNIST	0/90	0.0	0.19
0.1	Fashion	0/90	0.0	0.53
0.1	HAR	89/90	98.9	24.06
0.1	CIFAR-10	0/90	0.0	0.12
0.01	MNIST	90/90	100.0	42.57
0.01	Fashion	90/90	100.0	38.69
0.01	HAR	90/90	100.0	24.37
0.01	CIFAR-10	90/90	100.0	39.94

Diğer kurallarda alarm kanalı yoktur. Alarm mekanizmasının yokluğu alarm özgülüğü anlamına gelmediği için bu kurallara sıfır oran yazılmamıştır.

%96.59'a ulaşır. $\alpha = 0.01$ koşulunda saldırı başarısı daha düşüktür; ancak ana görev doğruluğu yalnızca %15.5–32.8'dir ve zehirlenmemiş kontrol bile bazı yamalı örnekleri hedef etikete atar (CIFAR'da %20.8). Bu yüzden doğruluk, saldırılı

ASR, kontrol ASR'si ve aralarındaki fark birlikte okunmalıdır; tek başına düşük bir ASR koruma sağlandığını göstermez.

Tablo VI

DÖRT KURALIN YAPILANDIRILMIŞ SALDIRI AİLESİNE GÖRE İSTEMCİ DÜZEYİNDE AYIRT ETME BAŞARIMI. $J = \text{TPR} - \text{FPR}$ YOUTEN İNDEKSİDİR: $J > 0$ ŞANS KÖŞGENİNİN ÜSTÜNÜ, $J < 0$ İSE DÜRÜST İSTEMCİLERİN SALDIRGANLARDAN ÖNCE REDDEDİLDİĞİNİ GÖSTERİR. FAYDA, AYNI KOŞULDA SAVUNMANIN DOĞRULUĞU EKSI SAVUNMASIZ DOĞRULUKTUR. HER SATIR YÖNTEM $\times$ VERİ KÜMESİ $\times$ KOŞUL HÜCRELERİNİ BİRLEŞTİRİR; HÜCRELER BAĞIMSIZ TEKRAR DEĞİLDİR.

Saldırgan ailesi	Hücre	TPR (%)	FPR (%)	J (yp)	Fayda (yp)
Yüksek Gauss gürültüsü ($\sigma = 5$)	60	87.5	18.9	+68.6	+13.7
Etiket çevirme	36	69.7	24.8	+45.0	-9.0
Yama arka kapısı	16	34.0	32.3	+1.8	-19.2
Sınırlı rastgele yön	72	34.1	33.7	+0.4	-23.0
Kısıtlı her şeyi bilen	28	21.8	38.0	-16.1	-10.6

Ailelerin kapsamı veri kümesi, yoğunlaşma parametresi ve saldırı oranı bakımından farklıdır. Bu özet radyal yer değiştirmeyi ölçmez. FLTrust sıfır ağırlık kararlarını kullanır. Bunlar kontrollü bir yer değiştirme deneyi değil, betimsel ortalamalardır.

VIII. KARAR YOLU ANALİZİ

Yeniden oynatma, MNIST ve Fashion'dan 72 kayıtlı güncelleme matrisi kullanır. Matrisler üç tohumu, 0, 9 ve 29. turları ve her biri 18 matrislik dört bloğu kapsar: Min-Max ve yama saldırıları ile bunların saldırısı kapatılmış kontrolleri. Saldırlı matrislerde 90 katılımcının 18'i saldırgandır; bu, yukarıdaki 27 saldırganlı kanonik kısıtlı yoklama hücrelerinden farklıdır. Her matris iki kapı ayarı ve iki komşuluk kesmesi seçeneği altında değerlendirilir. Matrisler yeniden kullanılan kontrol noktalarıdır, bağımsız eğitim tekrarları değildir.

A. Kapı çalışması ve ölçülen yarıçap koşulu

Kullanılan kapı altında küme aşaması 72 kontrol noktasının 10'unda çalışır; 36 saldırlı kontrol noktasının hiçbirinde çalışmaz. Yalnız yoğunluk kapısı (density-only gate), destekleyici ilk ret şartını kaldırır. İki komşuluk kesmesi ayarında da bu değişiklik 144 karşılaştırmaların hepsinde kabul kümesini değiştirmez.

$\Gamma(B_0)$ değerini arşivlenmiş matrislerde (2) içindeki tabanlı yarıçapla hesapladık. Her saldırlı matriste B_0 90 güncellenmenin tamamını içerir; dolayısıyla her aday grup $S \subseteq B_0$ koşulunu sağlar. Yeter koşul **36 farklı saldırlı matrisin 35'inde** sağlanır: 18 Min-Max matrisinin 18'inde ve 18 yama matrisinin 17'sinde (Tablo X). Medyan 1.448095, en büyük değer 2.017225'tir. İstisna Fashion, tohum 137, yama, tur 29'dur. İki kapıyı değerlendirmek aynı 36 matristen 72 satır üretir; bu, örneklem büyüklüğünü iki katına çıkarmaz.

Koşulu sağlayan 35 matriste B_0 üyelerinin hiçbir yeniden gruplanması, bir merkezi $2R_0$ yarıçaplı kabul topunun dışına taşıyamaz; bu da kapı açıldığında bile testin neden etkisiz kaldığını açıklar. Kalan matriste yeter koşul sağlanmaz ama bulunan gruplar yine de kabul edilir; bu durum önermeyle çelişmez, nedenin seyrelme (dilution) olduğunu da göstermez. float64'e yükseltme, Γ değerini yerel hesaba göre en fazla 5.43×10^{-7} değiştirir ve hiçbir eşik sınıflamasını değiştirmez.

Altküme kısıtı bu saldırlı bloğun dışında önemlidir. Komşuluk kesmesi etkin olan 144 kapı değerlendirmesinin altısında B_0 dışında üyeleri olan gruplar vardır ve yalnız B_0 kümesinin yarıçap oranı bu grupları onaylayamaz. Bu nedenle kontrol noktasına özgü açıklama, algoritmanın bütününe genişletilemez.

B. Yönlendirme ve doğrulama farklı olaylardır

Yalnız yoğunluk kapısı altında yama işleme, 18 saldırlı kontrol noktasının 17'sinde açılır. İşlenen bölümlerlerdeki 306 saldırgan gözleminin 285'i düşük yoğunlukludur; kesme etkinken bunların 239'u bulunan gruplara girer ve 55 grubun 30'u saldırgan içerir. Bu grupların hiçbirisi reddedilmez. Yani yama saldırganları grup testine ulaşır ve testi geçer; kullanılan kapı altında ise bu saldırlı kontrol noktalarında o aşamaya hiç ulaşmazlar.

Kısıtlı yoklama için de kayıtlı yönlendirme reddedilmiş bir saldırgan grubu üretmez. Uygulama sıfır uzaklık toplamında ideal ters uzaklık ifadesini izlemek yerine 1 döndürdüğü için tam kopyalara keyfi büyüklükte yoğunluk atanmaz. Bu nedenle gözlenen yönlendirmeyi ve bağımsız olarak denetlenen yarıçap koşulunu raporluyoruz; kopyalanmış vektör saldırısını Önerme 4 ile koşulsuz olarak açıklayıyoruz.

C. Kümelenmemiş güncellemelere müdahaleler

P0 politikası yalnız bulunan grupları test eder. P1 ayrıca kümelenmemiş düşük yoğunluklu noktaları tekil olarak test eder, P2 ise bu noktaları doğrudan dışlar. Her karşılaştırmada geometri, kayıtlı geçmiş ve bulunan grup üyeliği sabit tutulur.

P1 iki kapı altında da saldırgan reddi eklemeyi; buna karşılık kullanılan kapı altında 32, yalnız yoğunluk kapısı altında 77 dürüst ret ekler (Tablo XI). P2, yalnız yoğunluk kapısının yama bloğunda farklı davranır: $\text{TPR} = 46/324 = 14.20\%$, $\text{FPR} = 142/1296 = 10.96\%$ ve $J = +3.24$ puan. Eşleşen saldırısı kapatılmış blokta aynı politika 82 dürüst gözlemi reddeder. Yalnız yoğunluk kapısı altında Min-Max saldırlı matrislerde P2 bütün dürüst gözlemleri dışlardı; valf bu matrislerin 18'inin hepsinde B_0 kümesini geri yükler. Bunlar kontrol noktası sayımlarıdır; yeniden oynatma son doğruluğu veya saldırı başarısını yeniden ölçmez.

Olumsuz P1 sonucu, bu özel kapsam onarımının kayıtlı geometrilerdeki sınırını gösterir. Kapsamdaki veya doğrulama istatistiğindeki her değişikliğin başarısız olacağını göstermez. Özellikle ilk test ve uzlaşma testi (consensus test) farklı merkezler ve yarıçaplar kullanır; bu nedenle dışbükey zarf sınırı tek başına bu testlerin istemci düzeyindeki kararlarını sıralamaz.

Başka bir temiz MNIST kontrol noktası, aynı testin dürüst gruplara nasıl davrandığını gösterir (Tablo XII). Bu nokta $\alpha = 0.01$ ve beş sabit yerel adımlı ayrı bir koşumdan alınmış ve üç yerel mini-batch rejimi altında yeniden oynatılmıştır: 32 batch boyutlu standart yükleyici (A), her adımda yeni bir 20 örneklik altküme (B) ve beş kez tekrarlanan ilk 20 örneklik batch (C). Her rejimde bulunan en büyük grup ret yarıçapı τR_0 'ın 0.12–0.13 katı uzaklıktadır; daha küçük her grup ise bu yarıçapın 1.70–2.63 katı uzaklıktadır ve bütün katılımcılar dürüst olduğu hâlde reddedilir. A rejiminde reddedilen grupların ikisi tamamen B_0 dışındadır. Son ret sayısı A rejimindeki 34'ten B ve C rejimlerinde 25 ve 18'e düşer. A'da reddedilip C'de kabul edilen 16 istemcinin 10'u, bir grup testi geçtiği için değil, artık test edilebilir bir gruba ait olmadığı için retten kurtulur; diğer altısı ilk filtre kararlarındaki değişimi yansıtır. P1 altında üç rejimin hepsi 44 istemci reddeder; ancak C rejiminde bir kimlik çifti farklıdır. Bu örnek tek bir

Tablo VII

KURAL BAŞINA, MEVCUT HÜCRELER ÜZERİNDEN SALDIRI AİLESİ ORTALAMALARI. FLTrust BU PANELDE KISITLI AILEDE POZİTİF ORTALAMA J ELDE EDER; SAYIMLARI SIFIR AĞIRLIKLARA İLİŞKİNDİR. BU, SAVUNMA SINIFLARI ARASINDA GENEL BİR AYRIM KANITLAMAZ.

Saldırgan ailesi	Kural	Hücre	TPR (%)	FPR (%)	J (yp)	Fayda (yp)
Yüksek Gauss gürültüsü ($\sigma = 5$)	Multi-Krum	15	100.0	10.4	+89.6	+16.5
	FLTrust (normalize)	15	50.0	28.0	+22.0	+14.9
	FLAME (HDBSCAN)	15	100.0	31.5	+68.5	+6.2
	Fed-MDBSCAN-G (tam)	15	100.0	5.8	+94.2	+17.1
Etiket çevirme	Multi-Krum	9	69.1	22.4	+46.7	-9.5
	FLTrust (normalize)	9	79.0	26.7	+52.3	-4.7
	FLAME (HDBSCAN)	9	78.5	38.8	+39.7	-14.0
	Fed-MDBSCAN-G (tam)	9	52.3	11.1	+41.2	-7.9
Yama arka kapısı	FLTrust (normalize)	4	31.4	27.6	+3.8	-7.9
	FLAME (HDBSCAN)	6	48.4	47.5	+0.9	-26.7
	Fed-MDBSCAN-G (tam)	6	21.4	20.2	+1.2	-19.2
Sınırlı rastgele yön	Multi-Krum	18	33.7	31.7	+2.1	-23.2
	FLTrust (normalize)	18	29.7	29.8	-0.1	-9.3
	FLAME (HDBSCAN)	18	47.5	46.7	+0.9	-33.0
	Fed-MDBSCAN-G (tam)	18	25.3	26.7	-1.4	-26.3
Kısıtlı her şeyi bilen	Multi-Krum	6	9.7	41.9	-32.2	-20.1
	FLTrust (normalize)	6	66.3	30.7	+35.6	+14.1
	FLAME (HDBSCAN)	8	13.1	57.9	-44.7	-19.6
	Fed-MDBSCAN-G (tam)	8	6.4	20.6	-14.2	-12.9

Tablo VIII

KISITLI HER ŞEYİ BİLEN SALDIRGAN ALTINDA ÇALIŞMA NOKTALARI (%30 SALDIRGAN; TURDA 63 DÜRÜST VE 27 SALDIRGAN KATILIMCI). KABUL ARİTMETİĞİ SAYISAL BİR ÖNGÖRÜ VEREN İKİ KURAL GÖSTERİLMİŞTİR; DİĞER İKİSİ TABLO VII İÇİNDE ÖZETLENMİŞTİR. SON SÜTUN, SIFIR SALDIRGAN YAKALAMA KOŞULUNDA SONUÇ 1-2 İLE VERİLEN KARDİNALİTE ÖZDEŞLİĞİNİ VEYA ÜST SINIRI GÖSTERİR.

α	Veri kümesi	Kural	TPR (%)	FPR (%)	J (yp)	TPR = 0 ise FPR (%)
0.1	MNIST	Multi-Krum	0.00	46.03	-46.03	46.03
0.1	MNIST	FLAME (HDBSCAN)	0.00	68.11	-68.11	≤ 69.84
0.1	Fashion	Multi-Krum	0.00	46.03	-46.03	46.03
0.1	Fashion	FLAME (HDBSCAN)	0.00	65.59	-65.59	≤ 69.84
0.1	HAR	Multi-Krum	57.90	21.22	+36.68	46.03
0.1	HAR	FLAME (HDBSCAN)	96.67	27.25	+69.42	≤ 69.84
0.1	CIFAR-10	FLAME (HDBSCAN)	8.33	62.94	-54.60	≤ 69.84
0.01	MNIST	Multi-Krum	0.00	46.03	-46.03	46.03
0.01	MNIST	FLAME (HDBSCAN)	0.00	58.82	-58.82	≤ 69.84
0.01	Fashion	Multi-Krum	0.00	46.03	-46.03	46.03
0.01	Fashion	FLAME (HDBSCAN)	0.00	63.19	-63.19	≤ 69.84
0.01	HAR	Multi-Krum	0.00	46.03	-46.03	46.03
0.01	HAR	FLAME (HDBSCAN)	0.00	59.47	-59.47	≤ 69.84
0.01	CIFAR-10	FLAME (HDBSCAN)	0.00	57.51	-57.51	≤ 69.84

Multi-Krum her turda 90 gönderimin $n - m = 29$ tanesini atar. Altı hücrenin 5'inde tam olarak $2610 = 29 \times 90$ dürüst ret ile TPR = 0 kaydeder, yani FPR = $29/63 = 46.03\%$: atılan her gönderim dürüştür. İki tamamlanmış tohum ve bir kayıtlı başarısızlık nedeniyle 60 tur içeren CIFAR-10/FLAME/ $\alpha = 0.1$ dışında her hücrede 90 kayıtlı tur vardır. Koşullu özdeşlik TPR değeri pozitif olan satırlara uygulanmaz.

Tablo IX

TAM YÖNTEM İÇİN YAMA ARKA KAPISI BLOĞU VE EŞLEŞEN SALDIRISI KAPATILMIŞ KONTROLLER. DOĞRULUK VE TETİKLENMİŞ HEDEF DIŞI ÖRNEKLERDEKİ SALDIRI BAŞARISI BİRLİKTE VERİLMİŞTİR; DÜŞÜK DOĞRULUKLU $\alpha = 0.01$ BLOĞU ETKİLİ KORUMA OLARAK OKUNMAMALIDIR.

α	Veri kümesi	Doğr. (%)	ASR (%)	Kontrol doğr. (%)	Kontrol ASR (%)
0.1	MNIST	93.97	99.993	94.14	0.573
0.1	Fashion	83.34	99.930	83.42	2.630
0.1	CIFAR-10	49.55	96.589	49.85	5.756
0.01	MNIST	28.20	79.848	26.01	5.517
0.01	Fashion	32.83	56.178	32.24	1.848
0.01	CIFAR-10	15.47	26.856	15.83	20.796

Tablo X

FARKLI SALDIRILI KONTROL NOKTASI MATRİSLERİNDE İLK KABUL HAVUZUNUN RADYAL ORANI. EŞİK $\tau = 2$ DEĞERİDİR.

Saldırı	Matris	$\Gamma \leq 2$	Medyan	En büyük
Min-Max	18	18	1.257480	1.622338
Yama	18	17	1.665775	2.017225
Tüm saldırılı	36	35	1.448095	2.017225

İki kapı değerlendirmesi aynı matrisi kullandığından her matris bir kez sayılmıştır. 36 matrisin hepsinde B_0 90 katılımcının tamamını içerir. İstisna Fashion, tohum 137, yama, tur 29'dur.

kayıtlı durumdaki grup oluşumu ve kapsamla ilgilidir; istemci popülasyonunun büyüklüğü ile kötü niyet arasında genel bir ilişkiyi göstermez.

D. Uç nokta ablasyonları

Eşleşen 12 veri kümesi–koşul hücresi ve 36 uç nokta (end-point) koşumunda, yalnız 1. aşama varyantı ortalama son doğrulukta tam bileşik yöntemden -0.081 yüzde puan farklıdır. Valfi kaldırmak ortalama $+0.278$ puan değiştirir; kapı belleği (gate memory) olmayan varyant ise 36 uç noktanın hepsiyle eşleşir. Etkiler koşula göre değişir. Bu kadar küçük ortalama farklar varyantlar arasında eşdeğerlik kanıtlamaz ya da ek doğrulama olmadan birinin seçilmesini gerektilemez.

IX. TARTIŞMA

Ana ampirik bulgu, dürüst istemcilere çıkan maliyetin birkaç yapılandırma hiç saldırgan yokken bile önemli düzeyde kalmasıdır. Sabit kardinaliteli seçimde bu dışlama, seçilen sayıyla belirlenir. Küme tutma ise bir sınır getirir; doğrudan sayımlar bu sınıra ne sıklıkta ulaşıldığını gösterir. İki dışlama ölçütü de fayda ölçümünün yerini tutmaz: birleştirme hiçbir istemciyi reddetmeden doğruluğu düşürebilir, bir model de doğruluğunu korurken bir arka kapıyı öğrenebilir.

Bileşik yöntem için ölçülen yarıçap koşulu belirli bir tasarım teşhisi sağlar. Her aday grup, en büyük yarıçapı merkez testi eşliğinin altında kalan bir kabul havuzunun içindeyse, gruplamadaki hiçbir değişiklik bu testi etkinleştiremez. Bu yüzden kümeleme karmaşıklığı eklenmeden önce geometrik kapsamın denetlenmesi yararlıdır. Bu teşhis farklı bir grup istatistiğini, referans noktasını, eşik veya eğitim protokolünü dışlamaz. Benzer biçimde yoğunluk argümanı pozitif uzaklık toplamları ve ayırıcı bir eşik gerektirir; kopyaların nasıl ele alındığı da uygulanan kuralın raporlanması gereken bir parçasıdır.

Yararlı bir değerlendirme; hedeflenen heterojenlik düzeylerinde temiz dışlamayı ve faydayı, tam kabul ve geri dönüş kurallarını ve eşleşen kontrollerle birlikte saldırı tarafındaki TPR, FPR, doğruluk ve ASR değerlerini raporlamalıdır. Birlikte raporlandıklarında bu nicelikler, herhangi birinin tek başına gizleyebileceği başarısızlıkları ortaya çıkarır. Tek bir turda dışlanma, istemcinin kalıcı olarak çıkarılması veya modele verilen zararın doğrudan ölçüsü olarak betimlenmemelidir.

Bazı sınırlılıklar sürmektedir. Sonuçlar üç tohuma, kısa eğitim ufuklarına, küçük modellere ve eşit olmayan kapsama dayanır; bölümlenme onarımı da örneklenen heterojenliği değiştirir. Yerel referans yöntem uygulamalarının yazar kodlarına ve eğitim protokollerine sadakati yalnızca kısmen denetlenmiştir. CIFAR tekrarlanabilirliği tüm matris için değil, tek bir tanı koşulu için deterministik bir profil altında gösterilmiştir. Yeniden oynatmalar kayıtlı yörüngelere koşulludur; değiştirilmiş bir savunma ise sonraki girdileri değiştirirdi. Son olarak analiz geriye dönük olarak geliştirilmiştir ve yeni bir kuramın bağımsız doğrulamasını sağlamaz; temel özdeşlikler genel imkânsızlık teoremleri olarak değil, bu karar yollarının açıklamaları olarak okunmalıdır.

Güvenilir veri, zamansal bilgi, alternatif güncelleme temsilleri ve istemci tarafı doğrulama ek bilginin doğal kaynaklarıdır; ancak bu çalışma bunlardan herhangi birinin gerekli ya da yeterli olduğunu göstermez. Sonuçlar değerlendirilen kurallar ve koşullarla sınırlıdır; filtreleme kurallarının kendilerini iyileştirmek açık bir sorun olarak kalmaktadır.

X. SONUÇ

Saldırganız dışlamayı ve saldırı altındaki kararları, 2125 tamamlanmış koşum ve beş kayıtlı başarısızlık içeren bir federe öğrenme değerlendirmesinde sekiz sonucu tarafı kuralın seçim davranışıyla ilişkilendirdik. Multi-Krum'un temiz dışlaması sabit kardinalitesinden kaynaklanır; doğrudan FLAME sayımları ise küme boyutu sınırına ne zaman ulaşıldığını gösterir. Fed-MDBSCAN-G için denetlenmiş bir altküme koşulu ve yarıçap oranı, küme merkezi doğrulamasının 36 saldırılı kontrol noktası matrisinin 35'inde neden hiçbir aday grubu reddedemediğini açıklar. Daha önce test edilmeyen tekil güncellemeleri test etmek bu yeniden oynatmalarda saldırgan reddini iyileştirmez. Bu bulgular dürüst maliyetin, saldırı tespitinin ve saldırı başarısının, uygulama sınırları ve koşullu argümanlar açıkça belirtilerek birlikte raporlanmasını destekler.

VERİ VE KOD ERIŞİLEBİLİRLİĞİ

Ek yapıt; hücre ve birim düzeyindeki sonuçları, başarısızlık muhasebesini, kontrol noktası özetlerini ve makaledeki tabloları ve şekilleri yeniden üreten betikleri içerir. Proje deposu <https://github.com/Bygokcen/fed-mdbscan-g> adresindedir. Ham eğitim çıktıları ve dondurulmuş kaynaklar yerel araştırma arşivinde tutulur ve depo klonuna dahil değildir. Sağlanan özetler raporlanan aritmetiğin denetlenmesine olanak tanır; geçmiş kimlik ve kontrol noktası denetimlerini yeniden üretmek için ise bu arşiv de gereklidir.

Tablo XI

UZLAŞMA TESTİ KAPSAMININ 72 KAYITLI GÜNCELLEME MATRİSİ ÜZERİNDE YENİDEN OYNATILMASI; KÜME YAPISI, GEOMETRİ VE KAPI BELLEĞİ SABİT TUTULMUŞTUR. DEĞERLER, İSTEMCİ-KONTROL NOKTASI SAYIMI OLARAK DÜRÜST/SALDIRGAN RETLERİDİR. P0 KULLANILAN POLİTİKADIR (YALNIZ KÜMELER); P1 KÜMELENMEMİŞ DÜŞÜK YOĞUNLUKLU GÜNCELLEMELERİ AYRICA TEKİL OLARAK AYNI TESTE SOKAR; P2 BUNLARI DOĞRUDAN DIŞLAR. KAPSAMI GENİŞLETMEK DÜRÜST RET EKLER VE BİR BLOK DIŞINDA SALDIRGAN REDDİ EKLEMEZ.

Kapı / blok	P0 (yalnız kümeler)	P1 (+tekiler)	P2 (dışla)
Kullanılan kapı, Min-Max saldırılı	0/0	0/0	0/0
Kullanılan kapı, Yama saldırılı	0/0	0/0	0/0
Yalnız yoğunluk kapısı, Min-Max saldırılı	0/0	0/0	0/0
Yalnız yoğunluk kapısı, Yama saldırılı	0/0	1/0	142/46
Kullanılan kapı, Min-Max saldırısı kapatılmış kontrol	319/0	351/0	326/0
Yalnız yoğunluk kapısı, Min-Max saldırısı kapatılmış kontrol	319/0	395/0	404/0
Kullanılan kapı, Yama saldırısı kapatılmış kontrol	1/0	1/0	1/0
Yalnız yoğunluk kapısı, Yama saldırısı kapatılmış kontrol	1/0	1/0	82/0

Her saldırılı blok 1 296 dürüst ve 324 saldırgan gözlemi, her saldırısı kapatılmış blok 1 620 dürüst gözlemi içerir. Saldırgan reddi üreten tek blok (P2, yalnız yoğunluk kapısı, yama) $FPR = 142/1296 = 10.96\%$ düzeyinde $TPR = 46/324 = 14.20\%$ değerine ulaşır, yani $J = +3.2$ yp; aynı politika bu bloğun saldırısı kapatılmış kontrolünde 82 dürüst ret kaydeder. Sayımlar emniyet valfinden sonraki değerlerdir: yalnız yoğunluk kapısında P2, Min-Max bloğundaki 1 296 dürüst gözlemin hepsini dışlardı ve valf bu matrislerin 18'inin hepsinde B_0 kümesini geri yükler. Bunlar sabit matris karar sayımlarıdır; doğruluk ya da saldırı başarı oranı yeniden ölçülmemiştir.

Tablo XII

SEÇİLEN SALDIRGANSIZ MNIST KONTROL NOKTASINDA (TOHUM 2024, TUR 9), ÜÇ MINI-BATCH REJİMİ ALTINDA BULUNAN KÜMELER. ORAN, $\tau = 2$ VE R_0 (2) İLE TANIMLI OLMAK ÜZERE $\|c_S - m_{B_0}\|/(\tau R_0)$ DEĞERİDİR; ORAN 1'İ AŞINCA GRUP REDDEDİLİR. KARAR SÜTUNU UYGULAMANIN KENDİ ÇIKTISIDIR. BURADAKİ BÜTÜN İSTEMCİLER DÜRÜSTTÜR.

Kol	Küme	Boyut	B_0 içinde	Oran	Karar
A	0	38	38	0.13	kabul
A	1	6	6	1.84	ret
A	2	6	0	2.38	ret
A	3	4	4	1.90	ret
A	4	4	0	2.63	ret
A	5	4	4	1.99	ret
B	0	37	37	0.13	kabul
B	1	6	6	1.70	ret
B	2	4	4	1.87	ret
C	0	34	34	0.12	kabul
C	1	4	4	1.72	ret

Çoğunluk kümesi ret yarıcının 0.12–0.13 katı, her dürüst azınlık kümesi ise 1.70–2.63 katı uzaklıktadır. Ret yarıcayı dolayısıyla dürüst grupları birbirinden ayırmaktadır.

TEŞEKKÜR

Bu araştırma, kamu, ticari veya kâr amacı gütmeyen sektörlerdeki herhangi bir fon kuruluşundan özel bir destek almamıştır.

OpenAI ChatGPT/Codex ve Anthropic Claude; dil bilgisi düzeltmelerine, metnin hazırlanmasına ve gözden geçirilmesine (özet ve Bölüm I–X), analiz ve simülasyon kodunun geliştirilmesine ve iyileştirilmesine, matematiksel argümanların ve sayısal raporların denetlenmesine yardımcı olmuştur. Deneysel sonuçlar arşivlenmiş koşum kayıtlarından ve analiz betiklerinden türetilmiştir. Son içerikten yazarlar sorumludur.

Tablo XIII

VARYANT İLE TAM YÖNTEM ARASINDAKİ SON DOĞRULUK FARKI (YÜZDE PUAN), EŞLEŞEN ABLASYON BLOĞUNDA. ARALIKLAR KOŞULLAR ARASINDAKİ DEĞİŞKENLİĞİ GÖSTERİR, GÜVEN ARALIĞI DEĞİLDİR. 1. AŞAMA KABUL BÖLGESİNİN ÜZERİNDEKİ BÜTÜN KATMANLARI KALDIRMAK ORTALAMAYI YÜZDE PUANIN ONDA BİRİNDEN AZ DEĞİŞTİRİR.

Varyant	Hücre	Ort.	En az	En çok
Fed-MDBSCAN-G, yalnız 1. aşama	12	-0.081	-1.50	+0.84
Geometrik medyan uzaklık kontrolü	12	-0.081	-1.50	+0.84
Fed-MDBSCAN-G, kapı belleği yok	12	+0.000	+0.00	+0.00
Fed-MDBSCAN-G, valf yok	12	+0.278	-0.27	+3.03
Güven bölgesi çarpanı 1.5	12	-0.916	-8.42	+2.90
Güven bölgesi çarpanı 2.0	12	-0.860	-3.09	+2.95
Güven bölgesi çarpanı 3.0	12	+0.575	-6.38	+12.82

Hücreler üç tohum üzerinden veri kümesi $\times$ koşul ortalamalarıdır; küçük bir ortalama farktan eşdeğerlik sonucu çıkarılmamaktadır.

YAZAR KATKILARI

S. G. Özden: yöntem, yazılım, doğrulama, biçimsel analiz, araştırma, veri düzenleme, görselleştirme, özgün taslağın yazımı. K. Sarıkaya: kavramsallaştırma, danışmanlık, gözden geçirme ve düzenleme.

ÇIKAR ÇATIŞMASI BEYANI

Yazarlar, bu makalede raporlanan çalışmayı etkilemiş gibi görünebilecek bilinen hiçbir finansal çıkar çatışması veya kişisel ilişkileri bulunmadığını beyan eder.

KAYNAKLAR

- [1] B. McMahan, E. Moore, D. Ramage, S. Hampson, and B. A. y Arcas, "Communication-efficient learning of deep networks from decentralized data," in *Proc. 20th Int. Conf. Artificial Intelligence and Statistics (AISTATS)*, ser. PMLR, vol. 54, 2017, pp. 1273–1282.
- [2] M. Fang, X. Cao, J. Jia, and N. Z. Gong, "Local model poisoning attacks to Byzantine-robust federated learning," in *Proc. 29th USENIX Security Symp.*, 2020, pp. 1623–1640.
- [3] E. Bagdasaryan, A. Veit, Y. Hua, D. Estrin, and V. Shmatikov, "How to backdoor federated learning," in *Proc. 23rd Int. Conf. Artificial Intelligence and Statistics (AISTATS)*, ser. PMLR, vol. 108, 2020, pp. 2938–2948.

- [4] C. Xie, K. Huang, P.-Y. Chen, and B. Li, "DBA: Distributed backdoor attacks against federated learning," in *Proc. 8th Int. Conf. Learning Representations (ICLR)*, 2020.
- [5] P. Blanchard, E. M. E. Mhamdi, R. Guerraoui, and J. Stainer, "Machine learning with adversaries: Byzantine tolerant gradient descent," in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 30, 2017, pp. 119–129.
- [6] D. Yin, Y. Chen, K. Ramchandran, and P. L. Bartlett, "Byzantine-robust distributed learning: Towards optimal statistical rates," in *Proc. 35th Int. Conf. Machine Learning (ICML)*, ser. PMLR, vol. 80, 2018, pp. 5650–5659.
- [7] X. Cao, M. Fang, J. Liu, and N. Z. Gong, "FLTrust: Byzantine-robust federated learning via trust bootstrapping," in *Proc. Network and Distributed System Security Symp. (NDSS)*, 2021, arXiv:2012.13995.
- [8] T. D. Nguyen, P. Rieger, H. Chen, H. Yalame, H. Möllering, H. Fereidooni, S. Marchal, M. Miettinen, A. Mirhoseini, S. Zeitouni, F. Koushanfar, A.-R. Sadeghi, and T. Schneider, "FLAME: Taming backdoors in federated learning," in *Proc. 31st USENIX Security Symp.*, 2022, pp. 1415–1432.
- [9] G. Baruch, M. Baruch, and Y. Goldberg, "A little is enough: Circumventing defenses for distributed learning," in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 32, 2019, pp. 8632–8642.
- [10] V. Shejwalkar and A. Houmansadr, "Manipulating the Byzantine: Optimizing model poisoning attacks and defenses for federated learning," in *Proc. Network and Distributed System Security Symp. (NDSS)*, 2021.
- [11] A. K. Singh, A. Blanco-Justicia, and J. Domingo-Ferrer, "Fair detection of poisoning attacks in federated learning on non-i.i.d. data," *Data Mining and Knowledge Discovery*, vol. 37, no. 5, pp. 1998–2023, 2023.
- [12] P. Ye, Y. Li, K. He, Q. Li, T. Qin, X. Wang, K. Yang, C. Zhang, and J. Chen, "Breaking the illusion: A critical study of backdoor defense in federated learning with non-IID data," *IEEE Trans. Inf. Forensics Security*, vol. 20, pp. 13 264–13 279, 2025.
- [13] A. A. Bellachia, M. A. Bouchiha, and Y. Ghamri-Doudane, "SoK: Understanding backdoor attacks and defenses in federated learning," *Expert Systems with Applications*, vol. 325, p. 132558, 2026.
- [14] K. Pillutla, S. M. Kakade, and Z. Harchaoui, "Robust aggregation for federated learning," *IEEE Trans. Signal Process.*, vol. 70, pp. 1142–1154, 2022.
- [15] S. P. Karimireddy, L. He, and M. Jaggi, "Byzantine-robust learning on heterogeneous datasets via bucketing," in *Proc. 10th Int. Conf. Learning Representations (ICLR)*, 2022, arXiv:2006.09365.
- [16] Y. Allouah, S. Farhadkhani, R. Guerraoui, N. Gupta, R. Pinot, and J. Stephan, "Fixing by mixing: A recipe for optimal Byzantine ML under heterogeneity," in *Proc. 26th Int. Conf. Artificial Intelligence and Statistics (AISTATS)*, ser. PMLR, vol. 206, 2023, pp. 1232–1300, arXiv:2302.01772.
- [17] P. Rieger, T. D. Nguyen, M. Miettinen, and A.-R. Sadeghi, "DeepSight: Mitigating backdoor attacks in federated learning through deep model inspection," in *Proc. Network and Distributed System Security Symp. (NDSS)*, 2022, arXiv:2201.00763.
- [18] E. Kabir, Z. Song, M. R. U. Rashid, and S. Mehnaz, "FLShield: A validation based federated learning framework to defend against poisoning attacks," in *Proc. IEEE Symposium on Security and Privacy (SP)*, 2024, pp. 2572–2590.
- [19] P. Rieger, T. Krauß, M. Miettinen, A. Dmitrienko, and A.-R. Sadeghi, "CrowdGuard: Federated backdoor detection in federated learning," in *Proc. Network and Distributed System Security Symp. (NDSS)*, 2024, arXiv:2210.07714.
- [20] T. Krauß and A. Dmitrienko, "MESAS: Poisoning defense for federated learning resilient against adaptive attackers," in *Proc. 2023 ACM SIGSAC Conf. Computer and Communications Security (CCS)*, 2023, pp. 1526–1540.
- [21] Z. Chen, F. Wang, Z. Zheng, X. Liu, and Y. Lin, "Fedward: Flexible federated backdoor defense framework with non-IID data," *arXiv preprint arXiv:2307.00356*, 2023.
- [22] J. Yuan, Q. Zhang, N. Chen, S. Chen, and B. Xu, "A multi-granularity clustering approach for federated backdoor defense with the Adam optimizer," in *Proc. 34th Int. Joint Conf. Artificial Intelligence (IJCAI)*, 2025, pp. 6931–6939.
- [23] J. Qian, Y. Zhou, X. Han, and Y. Wang, "MDBSCAN: A multi-density DBSCAN based on relative density," *Neurocomputing*, vol. 576, p. 127329, 2024.
- [24] P. Viola and M. J. Jones, "Robust real-time face detection," *International Journal of Computer Vision*, vol. 57, no. 2, pp. 137–154, 2004.
- [25] M. Kloft and P. Laskov, "Security analysis of online centroid anomaly detection," *Journal of Machine Learning Research*, vol. 13, pp. 3681–3724, 2012.
- [26] O. Touat and S. Bouchenak, "Towards robust and bias-free federated learning," in *Proc. 3rd Workshop on Machine Learning and Systems (EuroMLSys)*, 2023.
- [27] O. Ajibuwa and O. T. Odeyomi, "On the hidden costs of fairness in Byzantine-robust decentralized federated learning under data heterogeneity," in *Proc. IEEE Int. Performance, Computing, and Communications Conf. (IPCCC)*, 2025.
- [28] Q. Li, D. Wu, D. Zhou, C. Lin, S. Liu, C. Wang, and C. Shen, "Robust adversarial defenses in federated learning: Exploring the impact of data heterogeneity," *IEEE Trans. Inf. Forensics Security*, vol. 20, pp. 6005–6018, 2025.
- [29] H. Zhang, Y. Liu, X. He, J. Wu, T. Cong, and X. Huang, "SoK: Benchmarking poisoning attacks and defenses in federated learning," *arXiv preprint arXiv:2502.03801*, 2025.
- [30] V. Shejwalkar, A. Houmansadr, P. Kairouz, and D. Ramage, "Back to the drawing board: A critical evaluation of poisoning attacks on production federated learning," in *Proc. IEEE Symp. Security and Privacy (S&P)*, 2022, pp. 1354–1371.
- [31] G. Abad, M. Krček, S. Koffas, B. Tajalli, M. Arazzi, R. Riaño, X. Xu, Z. Liu, A. Nocera, and S. Picek, "SoK: The last line of defense: On backdoor defense evaluation," *arXiv preprint arXiv:2511.13143*, 2025.
- [32] A. Djemaa, D. Djenouri, and P. Legg, "Heterogeneity-aware poisoning attacks and mitigation in federated learning: A comprehensive survey and taxonomy," *Electronics*, vol. 15, no. 13, p. 2876, 2026.
- [33] Y. LeCun, L. Bottou, Y. Bengio, and P. Haffner, "Gradient-based learning applied to document recognition," *Proceedings of the IEEE*, vol. 86, no. 11, pp. 2278–2324, 1998.
- [34] H. Xiao, K. Rasul, and R. Vollgraf, "Fashion-MNIST: A novel image dataset for benchmarking machine learning algorithms," *arXiv preprint arXiv:1708.07747*, 2017.
- [35] D. Anguita, A. Ghio, L. Oneto, X. Parra, and J. L. Reyes-Ortiz, "A public domain dataset for human activity recognition using smartphones," in *Proc. 21st European Symp. Artificial Neural Networks (ESANN)*, 2013, pp. 437–442.
- [36] A. Krizhevsky, "Learning multiple layers of features from tiny images," University of Toronto, Tech. Rep., 2009. [Online]. Available: <https://www.cs.toronto.edu/~kriz/learning-features-2009-TR.pdf>
- [37] T.-M. H. Hsu, H. Qi, and M. Brown, "Measuring the effects of non-identical data distribution for federated visual classification," *arXiv preprint arXiv:1909.06335*, 2019.