

Heterojen Federe Öğrenmede Dürüst İstemci Dışlama ve Uzlaşma Testinin Sınırları

Sebahattin Gökçen Özden ve Kadir Sarıkaya

Özet—Federe öğrenmede sunucu tarafı savunmalar, hangi istemci güncellemelerinin kabul edileceğine karar verir. Veriler heterojen olduğunda dürüst güncellemeler de aykırı görünebilir; oysa savunmalar genellikle yalnızca saldırgan varken değerlendirilir ve dürüst istemcileri reddetmenin bedeli ölçülmeden kalır. Bu bedeli sekiz sunucu tarafı kural için dört veri kümesinde, üç heterojenlik düzeyinde (Dirichlet $\alpha = 0.5, 0.1, 0.01$) ve beş saldırı ailesinde ölçüyoruz (2125 tamamlanmış koşum; kayda geçmiş beş başarısız koşum). Kurallar arasında, çok yoğunluklu kümelemeyi federe öğrenmeye uyarlayıp geometrik medyan kabul bölgesine dayandırarak tasarladığımız Fed-MDBSCAN-G filtresi de vardır. Saldırgan yokken Multi-Krum dokuz temiz koşulun hepsinde dürüst gönderimlerin %32.2'sini, FLAME %42.4–48.9'unu, Fed-MDBSCAN-G ise $\alpha = 0.01$ koşulunda %42.6'ya kadarını dışlar; son doğruluk, düz ortalamaya göre 65.55 yüzde puana kadar düşer. Multi-Krum ve FLAME'de dışlama, kuralın kaç güncelleme tuttuğundan kaynaklanır: 90'da 61 ve 990 temiz turun 719'unda izin verilen en küçük çoğunluk olan 46. Uzaklık kısıtlı bir saldırı altında Multi-Krum altı koşulun beşinde yalnız dürüst istemcileri reddetmiştir. Fed-MDBSCAN-G için, küme doğrulama aşamasının ilk kabul edilen güncellemelerden oluşan hiçbir grubu reddedemeyeceği bir koşul üretiyoruz. Koşul 36 saldırılı kontrol noktasının 35'inde sağlanmış; geometrik medyan bölgesinin üzerindeki bütün aşamaları kaldırmak ortalama son doğruluğu 0.1 yüzde puandan az değiştirmiştir. Bu bulgular geometrik savunmaların genel olarak değil, değerlendirilen uygulamaların başarısızlıklarını açıklar. Saldırgansız dürüst istemci dışlamasının ve doğruluk kaybının, saldırı tespiti ve saldırı başarısıyla birlikte raporlanmasını öneriyoruz.

Anahtar Kelimeler—Federe öğrenme, zehirlenme, dayanıklı birleştirme, veri heterojenliği, yanlış pozitifler, kümeleme tabanlı savunmalar.

I. GİRİŞ

FEDERE öğrenme, istemcilerin eğitim örneklerini sunucuda toplamadan, yerelde hesaplanan güncellemelerden ortak bir model eğitir [1]. Aynı ayırım, kötü niyetli istemcilerin zehirlenmiş güncellemeler (poisoned updates) göndermesine ya da manipüle edilmiş verilerle eğitim yapmasına da olanak tanır [2], [3], [4]. Sunucu tarafı savunmalar buna dayanıklı birleştirme (robust aggregation), güncelleme filtreleme (update

filtering) veya güvenilir bir referansa (trusted reference) karşı doğrulama ile karşılık verir [5], [6], [7], [8].

Bir filtreleme savunması iki ayrı soruyu yanıtlamak zorundadır: saldırganları dışlıyor mu ve yararlı dürüst katkıları (honest contributions) koruyor mu? İstatistiksel heterojenlik her ikisini de zorlaştırır. Dürüst istemciler turun merkezî eğiliminden uzak güncellemeler üretebilirken, koordineli saldırılar dürüst dağılıma yakın kalabilir [9], [10]. Önceki değerlendirmeler bu koşullarda yanlış pozitifleri (false positives), fayda kaybını ve arka kapı (backdoor) açıklarını belgelemiştir [11], [12], [13]. Bu bulgular, savunmaların saldırgan yokken de değerlendirilmesini ve bileşik bir savunmanın her aşamasının son karara nasıl katkı yaptığının incelenmesini gerektirir.

Bu bedel uygulamada önemlidir. Cihazlar arası (cross-device) ve Nesnelerin İnterneti kuruluşlarında verisi çoğunluktan en farklı olan istemciler, örneğin nadir sınıflara ya da alışılmadık sensör profillerine sahip olanlar, güncellemeleri aykırı görünen istemcilerdir. Onları reddeden bir savunma, hiç saldırgan yokken bile dayanıklılık uğruna kapsamdan ve adaletten ödün verir [11], [14], [15]. Tespit ve saldırı başarısını yalnızca saldırılı turlarda raporlayan değerlendirmeler bu ödünleşimi ölçmeden bırakır [16]. Kendi çıkış noktamız bir tasarım denemesiydi: çok yoğunluklu bir kümeleme algoritmasını, heterojen dürüst grupları reddetmek yerine tanıyacağını umarak federe filtrelemeye uyarladık. Güçlü heterojenlik altında dürüst istemci dışlaması yüzde onlar düzeyine ulaşıncaya soru şuna dönüştü: bileşik yöntemin hangi aşaması dürüst istemcileri dışlıyor ve sonraki aşamalar bu kararı geri alabiliyor mu?

Bu soruları, sekiz sunucu tarafı kuralın tamamlanmış bir değerlendirmesi ve Fed-MDBSCAN-G filtresinin (Şekil 1) ayrıntılı analiziyle inceliyoruz. Fed-MDBSCAN-G, tasarladığımız bileşik bir filtredir (composite filter); geometrik medyan tabanlı bir kabul bölgesini (geometric-median acceptance region), göreceli yoğunluk bölümlenmesini (relative-density partitioning) ve paylaşılan komşu küme doğrulamasını (shared-neighbour cluster validation) birleştirir. Amacımız bu değerlendirmede gözlenen maliyetleri ve başarısızlıkları açıklamaktır. Bileşik yöntemi genel olarak üstün bir savunma olarak sunmuyor, bulguları bütün geometrik filtreleme yöntemleri için bir sınır olarak da görmüyoruz.

İlk katkımız, $\alpha \in \{0.5, 0.1, 0.01\}$ Dirichlet yoğunlaşma (Dirichlet concentration) değerlerinde yapılan saldırgansız (adversary-free) bir karşılaştırmadır. Veri kümesi kapsamını açıkça belirtiyor, dürüst istemci dışlamasını (honest-client exclusion) son doğruluktaki değişimden ayrı ölçüyoruz. Sabit kardinaliteli seçim (fixed-cardinality selection) kesin bir dışlama

Bu belge, İngilizce gönderim sürümünün yazarlar için hazırlanmış Türkçe çalışma çevirisidir; dergiye gönderilecek metin İngilizce sürümdür. Sayılar İngilizce sürümle birebir karşılaştırılabilir diye ondalık ayrırcı olarak nokta kullanılmıştır.

S. G. Özden, Bilgisayar Mühendisliği Bölümü, Mühendislik ve Mimarlık Fakültesi, Tokat Gaziosmanpaşa Üniversitesi, Tokat, Türkiye (e-posta: sebahattin.ozden0025@gop.edu.tr; ORCID: 0009-0008-9280-444X).

K. Sarıkaya, Endüstri Mühendisliği Bölümü, Mühendislik ve Mimarlık Fakültesi, Tokat Gaziosmanpaşa Üniversitesi, Tokat, Türkiye (ORCID: 0000-0001-9015-6209).

Sorumlu yazar: Sebahattin Gökçen Özden.

oranı verir. Çoğunluk kümesini tutma (majority-cluster retention) ise bir üst sınır verir; bu sınıra ulaşıp ulaşılmadığını, küme boyutlarını yuvarlanmış ret oranlarından geri hesaplamak yerine kayıtlı FLAME kabul kümelerini doğrudan sayarak ölçüyoruz.

İkinci olarak, bileşik yöntemin karar yolunun (decision path) koşullu bir analizini veriyoruz. Küme içirme (set containment) ilişkisi, sonraki aşamaların hangi ilk dışlamaları geri alamayacağını belirler. Dışbükeylik (convexity) ise her aday grup ilk kabul havuzunun (initial acceptance pool) içinde kaldığında küme merkezi doğrulamasının (centroid validation) hiçbir grubu reddetmemesi için bir yeter koşul (sufficient condition) verir. Bu koşulu kayıtlı kontrol noktalarında (checkpoint) sınıyor ve varsayımlarının nerede sağlandığını raporluyoruz. Ayrı bir skor sıralaması sonucu, bir kuralın ne zaman dürüst istemcileri reddedip hiçbir saldırganı reddetmediğini belirtir. Bu sonuç açık bir skor sıralaması gerektirir; saldırıya getirilen bir uzaklık kısıtı (distance constraint) bu sıralamayı her savunma skoru için tek başına garanti etmez.

Üçüncü olarak, sabit matrisler üzerindeki yeniden oynatmalar (replay), kümelenmemiş (unclustered) düşük yoğunluklu (low-density) güncellemelerin ele alınışında iki değişikliği sınar. Bu güncellemeleri tekil (singleton) olarak test etmek incelenen matrislerde saldırgan reddi eklemeyi; doğrudan dışlamak ise bir yama arka kapısı bloğunda farklı bir ödünleşim verir. Yeniden oynatmalar, test kapsamının (test coverage) eksikliğini doğrulama kuralının kendi başarısızlığından ayırır. Bunlar kayıtlı durumlardaki kararlarla ilgilidir; yeniden eğitilmiş varyantların doğruluğu veya saldırı başarısıyla ilgili değildir.

Değerlendirme 2 130 planlı kural-koşul-tohum biriminden (unit) oluşur ve bunların 2 125'i tamamlanmıştır; beş başarısız birim hesapta tutulmaktadır. Bu geriye dönük ve betimsel analiz, kontrollü gözlemleri açık karar kurallarına ve yeter koşullara bağlar. Yeni evrensel alt sınırlar ya da bir kuramın ileriye dönük doğrulanmasını ortaya koymaz.

Bölüm II ilgili çalışmaları gözden geçirir, Bölüm III sistem modelini ve değerlendirilen bileşik yöntemi tanımlar. Bölüm IV koşullu analizi geliştirir, Bölüm V deney protokolünü açıklar. Bölüm VI ve Bölüm VII saldırganlı ve saldırganlı tur sonuçlarını raporlar; Bölüm VIII kayıtlı kontrol noktalarında karar yollarını analiz eder. Bölüm IX bulguları tartışır, Bölüm X sınırlılıkları belirtir ve Bölüm XI çalışmayı sonuçlandırır.

II. İLGİLİ ÇALIŞMALAR

A. Dayanıklı birleştirme ve heterojen veri

Komşuluk tabanlı seçim, koordinat bazında kestiriciler, geometrik medyan ile birleştirme ve güven önyüklemesi (trust bootstrapping), zehirlenmiş güncellemelerin etkisini farklı varsayımlar altında sınırlar [5], [6], [17], [7]. Heterojen veri için önceki analizler, belirtilen varsayımlar altında istatistiksel sınırlar ortaya koyar ve dayanıklı birleştirme yapıları önerir [18], [19]. Bizim sonuçlarımız farklı bir nicelikte, yani belirli bir turda hangi istemcilerin kabul edildiği ya da dışlandığıyla ilgilidir. Bölüm IV içindeki temel küme ve dışbükeylik argümanları optimizasyon hatası sınırlarının yerini tutmaz ve model doğruluğu için bir sınır da ima etmez.

FLAME kümeleme, kırpma ve gürültüyü birleştirir [8]. DeepSight model davranışını inceler ve kümelemeyi şüphe tahminleriyle birleştirir [20]; FLShield istemci tarafı doğrulamaya dayanır [21]; CrowdGuard ve MESAS birden fazla aşama veya istatistik kullanır [22], [23]; Fedward ve FLAC ise kümeleme tabanlı savunmaları daha da geliştirir [24], [25]. Yoğunluk tabanlı filtreleme hâlâ gelişmektedir: Venkata Ramana vd. uyarlanabilir komşuluk seçimini, çok ölçütlü yoğunluk kestirimini ve medyan mutlak sapma eşiklemeğini birleştirir ve sabit bant genişlikli yerel yoğunluk tabanlı bir yöntemle göre daha düşük yanlış pozitif oranı raporlar [26]. Bu karşılaştırma da, burada atfı yapılan diğerleri gibi, saldırgan varken ölçülmüştür. Bu tasarımlar neyi gözlemledikleri ve nasıl karar verdikleri bakımından farklı olduğundan, bir aşama için kanıtlanan cebirsel bir özellik varsayımları denetlenmeden diğerlerine aktarılamaz.

Burada incelenen bileşik yöntem, göreceli yoğunluk bölümlenmesini ve paylaşılan komşu kümelemesini MDBSCAN algoritmasından uyarlar [27]. Filtre olarak kullanımı, komşuluk kesmesi (neighbourhood cutoff) ve kümelenmemiş noktaları ele alışı özgün kümeleme algoritmasından farklıdır; değerlendirdiğimiz şey bu yerel uyarlamadır. Kabul kümesi içirme argümanı, birleşik (conjunctive) kaskadların (cascade) bilinen bir özelliğidir [28]; burada önemli olan, kullanılan geri dönüş (fallback) mekanizmasının ilk havuza içerilmeyi koruyup korumadığıdır. Saldırı altında merkez tabanlı anomali tespiti üzerine yapılan çalışmalar, kabul bölgeleri ile saldırgan girdiler arasındaki etkileşim için ilgili bir bağlam sunar [29].

B. Yanlış pozitifler ve önceki değerlendirmeler

Adalet (fairness) çalışmaları, savunmaların istatistiksel olarak sıra dışı dürüst istemcileri nasıl dışladığını incelemiştir [11], [14], [15]. IID olmayan veri altında federe öğrenmeye ilişkin yakın tarihli değerlendirmeler de savunma başarımının kötüleştiğini belgeler [30], [12]. Bellachia vd., saldırganların dağınık bir dürüst popülasyon içinde gizlenmesini açıkça betimler [13]; bu mekanizmayı onların çalışmasına atfediyoruz.

Şans köşegeninin (chance diagonal) altındaki çalışma noktaları (operating point) önceki çalışmalarda da görülür. Bellachia vd.'nin Tablo 8'i, IID olmayan bir IBA koşulunda FLAME için TPR = 0 ve FPR = 0.45 raporlar [13]. Ye vd.'nin Tablo V'inde Dir(0.1) için verilen TPR/TNR çiftleri, FoolsGold ve CrowdGuard için sırasıyla $J = -4.15$ ve -6.8 yüzde puan anlamına gelir [12]. Dolayısıyla negatif J , burada değerlendirilen uzaklık kısıtlı yoklamalara (probes) özgü değildir.

Farklı çalışmalardan gelen oranları karşılaştırmak, paydalarına ve deney ayarlarına dikkat etmeyi gerektirir. Örneğin Ye vd., FLAME için Dir(0.5) koşulunda %73.29, Dir(0.1) koşulunda %54.87 TNR raporlar; bunlar %26.71 ve %45.13 FPR değerlerine karşılık gelir. Bu saldırganlı tur oranları, bizim saldırganlı sonuçlarımızdan farklı kohort boyutlarına ve paydalara dayanır; bu nedenle yapılandırılmamızın %48.89'luk üst sınırını ne doğrular ne de çürütür.

Değerlendirme yöntemi başlı başına bir araştırma konusudur. Shejwalkar vd. zehirlenme tehdit modellerinin ne kadar

gerçekçi olduğunu inceler [31]; Abad vd. ise arka kapı içermeyen kontrollerin rolünü tartışır [32]. Heterojenliği gözetken yakın tarihli bir tarama da savunma değerlendirmelerinin dürüst non-IID istemcilere karşı yanlış pozitifleri ve dürüst istemci dışlamasını raporlaması gerektiğini savunur [16]. Bizim katkımız saldırganlıktan kontrollerin, karar yolu ölçümlerinin ve tek bir bileşik yöntemin koşullu analizinin yeniden üretilebilir bir birleşimdir. Ne dürüst kontroller ne de negatif J gözlemi için öncelik iddia ediyoruz.

III. SİSTEM MODELİ VE KARAR KURALLARI

A. Protokol ve tehdit modeli

r turunda i istemcisi w_r modelini alır ve yerel model farkı (local model delta) $u_{r,i} = w_{r,i}^{\text{local}} - w_r$ güncellemesini gönderir. B_r indekslerini kabul eden düz ortalama (uniform mean) filtresi $w_{r+1} = w_r + |B_r|^{-1} \sum_{i \in B_r} u_{r,i}$ güncellemesini uygular. Paneldeki diğer kurallar kendi ağırlıklandırma, kırma veya koordinat bazında birleştirme yöntemlerini kullanır; düz ve örnek ağırlıklı ortalama (sample-weighted mean) ayrı referans yöntemler olarak yer alır.

Sunucu güvenilirdir ve istemci kimlikleri sabittir. Saldırganlar kendi eğitim verilerini veya gönderdikleri güncellemeleri kontrol eder. Min-Max ve Min-Sum yoklamaları her şeyi bilen (omniscient) türdendir; mevcut dürüst güncellemeleri de gözlemler ve ilgili uzaklık sınırına uyan ortak bir kötü niyetli vektör oluştururlar. Gerçek kötü niyetli kimlikler bu saldırıları oluşturmak ve kararları puanlamak için kullanılır; savunmaya hiçbir zaman girdi olarak verilmez.

$U = \{1, \dots, n\}$ gönderimleri (submission) indekslesin; H ve A da U kümesini dürüst ve saldırgan katılımcılara ayırsın. $|H| > 0$ olsun. Kabul edilen B indeksleri için $\text{FPR} = |H \setminus B|/|H|$ ve $|A| > 0$ olduğunda $\text{TPR} = |A \setminus B|/|A|$ tanımlansın. Bunların farkı Youden indeksi (Youden's index) $J = \text{TPR} - \text{FPR}$ ile verilir. Saldırganlıktan turlarda FPR değerine dürüst istemci dışlama oranı (benign exclusion rate, BER) diyoruz. Bu nicelikler katılım kararlarını betimler; doğruluğu veya arka kapı başarısını betimlemez.

Tanım 1 (Skor sıralı kural / Score-order rule): Gerçek s_i skorları verildiğinde, skor sıralı bir kural en yüksek skorlu k gönderimi veya belirli bir eşik için $s_i > \rho$ olanları atar. Eşit skorlar için belirli bir seçim kuralı tanımlanmalıdır. Radyal uzaklık ve en yakın komşu (nearest neighbour) uzaklık toplamları bu tür skorlara örnektir. Bölüm IV içindeki teorem, farklı skorların aynı sıralamayı ürettiğini varsaymaz. Küme üyeliği ikili bir skor olarak kodlanabilir; ancak bu kodlama, skorun uzaklık kısıtlı bir saldırıyla ilişkisi hakkında ek bir şey söylemez.

Tanım 2 (Monoton kaskad / Monotone cascade): Her ara kabul kümesi bir öncekinin altkümesi ise kaskad monotonudur. Daha önce çıkarılmış indeksleri geri kabul eden bir geri dönüş mekanizması bu özelliği bozabilir.

B. Değerlendirilen bileşik yöntem

Fed-MDBSCAN-G, heterojen veriye ilişkin bir hipotez etrafında tasarlandı. IID olmayan bölümlerle dürüst güncellemeler turun merkezi çevresinde tek bir yoğun bulut

oluşturmak zorunda değildir; farklı yoğunluklarda birkaç grup oluşturabilirler. MDBSCAN [27], düşük yoğunluklu noktaları göreceli yoğunlukla ayırır ve paylaşılan en yakın komşularla kümeler; bu nedenle her seyrek güncellemeyi ayırıcı saymak yerine bu tür grupları ilke olarak bulabilir. Ancak tek başına bir kümeleme aşaması, hangi grubun dürüst uzlaşmayı temsil ettiğini belirlemez. Bu yüzden onu, kırılma noktası (break-down point) yarım olan ve keyfi güncellemelerden oluşan bir azınlığın etkisini sınırlayan geometrik medyan kabul bölgesine dayandırdık [17]. Şekil 1 ortaya çıkan üç aşamalı karar yolunu özetler; aşağıdaki paragraflar her aşamayı tanımlar.

Fed-MDBSCAN-G yönteminin ilk filtresi (initial filter) şu kümeyi kabul eder:

$$B_0 = \{i : \|u_i - m\|_2 \leq \rho \text{ median}_j \|u_j - m\|_2\}, \quad \rho = 2.5, \quad (1)$$

burada m , geometrik medyanın Weiszfeld yaklaşımıdır. Gönderimlerin yarısından azı kalırsa ilk havuz U olarak sıfırlanır.

$k' = \min(5, n-1)$ için yoğunluk, k' en yakın komşuya olan uzaklıkların toplamı d_i üzerinden hesaplanır. Yerel uygulama $d_i > 0$ olduğunda $k' / \max(d_i, 10^{-15})$, $d_i = 0$ olduğunda 1 döndürür; tek elemanlı girdi de 1 döndürür. Kullanılan kapı (deployed gate), boşluk eşiği 10 olan bir yoğunluk boşluğu göstergesi (density-gap indicator) en az $\max(2, \lceil 0.05n \rceil)$ ilk retle birlikte gerçekleştiğinde açılır. Üç turluk bir bellek, daha önceki bir etkinleşmeden sonra küme aşamasını (cluster stage) temiz turlarda sönümlenmek kaydıyla etkin tutabilir.

Küme aşaması etkin olduğunda bütün gönderim kümesini yoğunluğa göre bölümler ve düşük yoğunluklu L altkümeleri üzerinde paylaşılan komşu kümelemesi çalıştırır. Bulunan her S grubu şu koşulda reddedilir:

$$\|c_S - m_{B_0}\|_2 > \tau R_0, \quad R_0 = \max(10^{-10}, \text{median}_{j \in B_0} \|u_j - m_{B_0}\|_2), \quad (2)$$

burada c_S grubun aritmetik merkezi (arithmetic centroid), m_{B_0} ise B_0 kümesinin geometrik medyanıdır ve $\tau = 2$ alınır. Bulunan bir gruba atanmamış noktalar bu aşamada test edilmez. Aday gruplar $L \cap B_0$ kümesinden değil L kümesinden oluşturulduğu için B_0 dışındaki indeksleri içerebilir.


Birleşik küme, reddedilen grupların üyelerini B_0 kümesinden çıkarır. Ardından gönderimlerin yarısından azı kalırsa bir valf (safety valve) B_0 kümesini geri yükler. Bu nedenle tam yol monoton bir kaskad olmak zorunda değildir; ancak son çıktı her zaman $B \subseteq B_0$ koşulunu sağlar ve aşağıdaki ilk dışlama sonucunun gerektirdiği yalnızca budur.

IV. KOŞULLU ANALİZ

Bu bölümdeki önermeler tek bir tura ve az önce tanımlanan karar kurallarına ilişkindir. Yalnızca küme içirme, kardinalite ve dışbükeyliğe dayandıkları için ampirik geçerlilikleri, varsayımlarının uygulanan yolda sağlanıp sağlanmadığına bağlıdır; Bölüm VIII bunu kayıtlı kontrol noktalarında denetler.

A. Kabul kümesi içirme ve kardinalite

Önerme 1 (İlk dışlama tabanı / Initial exclusion floor): $B \subseteq B_0$ ise $\text{FPR}(B) \geq \text{FPR}(B_0)$ olur ve $|A| > 0$ için



Şekil 1. Fed-MDBSCAN-G yönteminin karar yolu. (a) Aşama 1 geometrik medyan çevresinde ilk havuz B_0 'ı oluşturur; Aşama 2 küme aşamasını yalnızca göreceli yoğunluk boşluğu Aşama-1 retleriyle birlikte görüldüğünde açar; Aşama 3 düşük yoğunluklu kümeyi kümeler ve merkezi B_0 'ın geometrik medyanından τR_0 'dan daha uzak olan grupları reddeder. Son küme her zaman $B \subseteq B_0$ koşulunu sağlar. (b) Kullanılan aşama fonksiyonlarının sentetik noktalar üzerinde ürettiği açıklayıcı iki boyutlu örnek (deney verisi değildir). Aşama 1 saldırganları dokuz düğümle birlikte dışlar; Aşama 3'ün reddettiği iki grubun tamamı B_0 dışında kaldığından küme aşaması kabul kümesini değiştirmez. Bölüm VIII, kayıtlı kontrol noktalarında her aşamanın ne sıklıkla çalıştığını raporlar.

$\text{TPR}(B) \geq \text{TPR}(B_0)$ sağlanır. Bu, monoton bir kaskad ve en fazla B_0 kümesini geri yükleyen bir geri dönüş mekanizması için geçerlidir.

İspat: $H \setminus B_0 \subseteq H \setminus B$ ve $A \setminus B_0 \subseteq A \setminus B$ içermeleri, ilgili popülasyon boyutlarına bölündükten sonra eşitsizlikleri verir.

Dolayısıyla sonraki aşamalar, ilk filtrenin dışladığı düğüm bir istemciyi geri kabul edemez. Yine de çalışma noktasını iyileştirebilirler; örneğin ek düğüm istemci reddetmeden ek saldırganları reddedebilirler. Bu yüzden önerme bir Pareto iyileşmesini dışlamaz.

Sonuç 1 (Sabit kardinaliteli seçim / Fixed-cardinality selection): n gönderimin tam olarak m tanesi kabul ediliyorsa saldırganlar bir turda $\text{BER} = 1 - m/n$ olur. a saldırgan ve reddedilen t saldırgan varken, $n > a$ koşuluyla $\text{FPR} = (n - m - t)/(n - a)$ olur.

İspat: Toplam $n - m$ ret vardır; bunların t tanesi saldırgan, $n - m - t$ tanesi düğüştür.

Multi-Krum yapılandırılmamız $f = \lceil 0.3n \rceil$ ve $m = n - f - 2$ kullanır. $n = 90$ iken 61 güncelleme tutar; bu yüzden temiz BER değeri 29/90 olur. $a = 27$ ve $t = 0$ iken saldırlı turdaki FPR değeri 29/63 olur. Bu özdeşliklerle uyum yalnızca seçim kardinalitesini doğrular (Bölüm V-C).

Sonuç 2 (Çoğunluk kümesini tutma / Majority-cluster retention): Saldırganlar bir turda, boyutu $c \geq c_{\min}$ olan tek bir kümeyi tutan kural için $\text{BER} = (n - c)/n \leq (n - c_{\min})/n$ olur. Eşitlik ancak ve ancak $c = c_{\min}$ olduğunda sağlanır. a saldırgan ve t saldırgan reddiyle $\text{FPR} = (n - c - t)/(n - a)$ olur.

İspat: Küme dışında kalan reddedilmiş indeksleri sayın ve saldırgan retlerini çıkarın.

Yerel FLAME yolu $n = 90$ iken $c_{\min} = \lfloor n/2 \rfloor + 1 = 46$ kullanır; bu da 44/90 değerinde temiz bir üst sınır verir. Heterojenlik tek başına eşitliği zorunlu kılmaz. Kümelemenin başarısız olduğu veya geri dönüş mekanizmasının devreye girdiği turlar, fiilen yürütülen yola göre ele alınmalıdır.

B. Küme merkezi doğrulaması

Önerme 2 (Dışbükey zarf yarıçap sınırı / Convex-hull radius bound): Boş olmayan bir S grubu, güncellemelerinin herhangi bir dışbükey birleşimi (convex combination) $g(S)$ ve herhangi bir m_0 referansı için

$$\|g(S) - m_0\| \leq \max_{i \in S} \|u_i - m_0\|$$

sağlanır. s üyenin düz ortalaması için, bir üyenin yarıçapı en fazla r_a , diğerlerinin en fazla r_b ise

$$\|c_S - m_0\| \leq \frac{r_a + (s - 1)r_b}{s}$$

olur.

İspat: $g(S) - m_0$ ifadesini $u_i - m_0$ vektörlerinin dışbükey birleşimi olarak yazın ve üçgen eşitsizliğini uygulayın. İkinci ifade $1/s$ ağırlıklarını kullanır.

Buna göre bir grup merkezi bir topun dışındaysa en az bir üye de dışındadır. Bu ifade tek tek üyelere değil gruba ilişkindir. Bütün bir grubu reddetmek topun içindeki üyeleri de dışlayabilir: gerçel doğru üzerinde merkez 0 ve yarıçap 2 iken $\{1, 5\}$ grubunun merkezi 3'tür; üyesi 1 topun içinde olduğu hâlde grup reddedilir. Tersine, sapmalar birbirini götürerek bir üye dışarıdayken merkezi topun içine yerleştirebilir. İlk filtre ve uzlaşma filtresi (consensus filter) de farklı referans noktaları ve yarıçaplar kullanır; bu nedenle sınır, bu iki filtrenin istemci düzeyindeki kararlarını sıralamaz.

Önerme 3 (Küme merkezi doğrulamasının etkisiz kalması için yeter koşul / Sufficient condition for inactive centroid validation): Boş olmayan B_0 için

$$\Gamma(B_0) = \frac{\max_{i \in B_0} \|u_i - m_{B_0}\|_2}{R_0}$$

tanımlansın; burada R_0 , (2) içindeki tabanlı yarıçaptır (floored radius). $\Gamma(B_0) \leq \tau$ ise boş olmayan hiçbir $S \subseteq B_0$ grubu (2) ile reddedilmez. Test edilen her grup böyle bir altkümeyle ve başka hiçbir aşama üye çıkarmıyorsa son kabul kümesi $B = B_0$ olur.

İspat: B_0 kümesinin her üyesi m_{B_0} merkezli, τR_0 yarıçaplı kapalı topun içindedir. Top dışbükey olduğundan bir $S \subseteq B_0$ altkümesinin üyelerinin her dışbükey birleşimi topun içindedir ve kesin ret eşitsizliği sağlanamaz. ■

Koşul yeterlidir ama gerekli değildir. Ayrıca aday grupları B_0 dışındaki üyeleri içerebilen bileşik yöntemimiz için genel olarak geçerli değildir. Örneğin $B_0 = \{-1, 1\}$ için $\Gamma = 1$ olur; ama $\{1, 10\}$ grubunun merkezi 5.5 olduğundan grup yarıçap-2 testini geçemez. Bu yüzden önermeyi kayıtlı matrislere uygulamadan önce altküme koşulunu doğruluyoruz.

C. Yoğunluk sıralaması ve uygulama sınırı

Önerme 4 (Ayrıcı eşikle yoğunluk ayrımı / Density separation with a separating threshold): Uzaklık toplamalarının kesinlikle pozitif olduğu ideal $\text{rd}(i) = k'/d_i$ skorunu ele alalım. $|A| \geq k' + 1$ olsun; bütün saldırgan çiftleri arasındaki uzaklıklar en fazla $\delta_A > 0$ ve her dürüst noktanın ortalama k' -en yakın komşu uzaklığı en az $\delta_H > \delta_A$ olsun. O zaman

$$\min_{a \in A} \text{rd}(a) \geq 1/\delta_A > 1/\delta_H \geq \max_{i \in H} \text{rd}(i)$$

olur. $\max_{i \in H} \text{rd}(i) < t \leq \min_{a \in A} \text{rd}(a)$ koşulunu sağlayan bir eşik için $L = \{i : \text{rd}(i) < t\}$ kümesi bütün dürüst noktaları içerir ve hiçbir saldırgan noktayı içermez.

İspat: Her saldırganın δ_A uzaklık içinde k' başka saldırganı vardır; bu nedenle en yakın komşu uzaklık toplamı en fazla $k'\delta_A$ olur. Varsayılan dürüst ortalama uzaklık $d_i \geq k'\delta_H$ verir. Terslerini almak sıralamayı, eşik koşulu da seçilen kümeyi verir. ■

Eşik kısıtı zorunludur, çünkü bütün skorların üzerindeki bir eşik saldırganları da seçer. Önerme, yerel uygulamadaki tam kopyalara (exact duplicates) da doğrudan uygulanmaz. Etkin en yakın komşu uzaklıklarının toplamı sıfır olduğunda kod $\text{rd} = 1$ döndürür; $k' = 1$ ile tek boyutlu $[0, 0, 0.1, 0.2]$ girdisi için gerçek çıktı $[1, 1, 10, 10]$ olur. Bu davranışı çalışma kaynağında ve iki dondurulmuş (frozen) kopyada yeniden ürettik. Dolayısıyla tam kopyalama tek başına Önerme 4 içindeki yüksek yoğunluk sıralamasını üretmez. Kümeleme sezgisi önceki gözlemlerle uyumludur [13]; ancak belirli bir koşumu (run) açıklamak, o koşumda hesaplanan skorları ve yönlendirme (routing) kararlarını gerektirir.

D. Koşullu bir skor sıralaması sonucu

Teorem 1 (Yalnız dürüst ret / Honest-only rejection): H ve A boş olmasın ve $1 \leq k \leq |H|$ olsun. Bir kural en yüksek

Tablo I
BLOKLARA GÖRE PLANLANAN DEĞERLENDİRME KAPSAMI

Blok	Birim
Ana matris (saldırlı ve saldırgansız)	1500
Ablasyon varyantları	252
Eşleşen saldırısı kapatılmış kontroller	156
Kâhin (oracle) tanıları	78
Alternatif bölümlene politikası	54
Sabit yerel adım kontrolü	54
Saldırı başlangıç/bitiş zamanlaması	36
Planlanan toplam	2130

Bir birim, bir kural-koşul-tohum koşumudur. Planlanan 2130 birimin 2125'i tamamlanmış, 5'i doldurulmak ya da yeni tohumla tekrarlanmak yerine başarısız olarak tutulmuştur. Bloklar dengeli bir tam faktöriyel tasarım oluşturmaz.

Tablo II
DENEY DÜZENİ

Öğe	Ayar
MNIST, Fashion-MNIST	çok katmanlı algılayıcı 784–200–10
UCI HAR	çok katmanlı algılayıcı 561–128–64–6, dropout 0.2
CIFAR-10	iki evrişim katmanı (32, 64 kanal) ve tam bağlantılı katmanlar 256–10
İstemciler	toplam 100, turda 90 katılımcı
Eğitim	30 tur, 3 yerel epok, mini-batch boyutu 32
Optimizasyon	öğrenme oranı 0.01, momentum 0.9
Tohumlar	42, 137, 2024
Bölümleme	Dirichlet, $\alpha \in \{0.5, 0.1, 0.01\}$, istemci başına ≥ 20 örnek

k skoru atıyorsa ve $s_{(k)}^H$ en büyük k 'inci dürüst skor olmak üzere $\max_{a \in A} s_a < s_{(k)}^H$ ise

$$\text{TPR} = 0, \quad \text{FPR} = k/|H|, \quad J = -k/|H|$$

olur. Eşik kuralı için, $\rho \geq \max_{a \in A} s_a$ ise aynı sonuç $k = |\{i \in H : s_i > \rho\}| > 0$ ile geçerlidir.

İspat: Kesin sıralama, atılan k indeksin hepsini H içine yerleştirir. Eşik durumunda hiçbir saldırgan eşik aşmaz. Dürüst ve saldırgan retlerini sayın. ■

Teorem koşullu bir sayma sonucudur. Min-Max ve Min-Sum uzaklıkları kısıtlar [10], ancak bu kısıtlar teoremin sıralama öncülünü her skor için sağlamaz. Örneğin $\{-2, 0, 0.1, 2\}$ dürüst noktalarının en büyük ikili uzaklığı 4'tür ve -1 noktası her birine en fazla 3 uzaklıktadır; yine de dürüst geometrik medyana en uzak üç noktayı reddeden bir kural, -2 ve 2 ile birlikte -1 noktasını da reddeder. Negatif J ayrıca model doğruluğu veya saldırı başarısı hakkında doğrudan bir şey söylemez. Ret bütçesini büyütme J değerini ancak yalnız dürüst sıralaması korunduğu sürece daha negatif yapar.

Ne içirme ne de dışbükeylik sonucu referans noktasının nasıl elde edildiğine bağlıdır; bu nedenle ikisi de güvenilir sonucu verisi kullanan kurallara uygulanır. FLTrust'ın Bölüm VII içinde elde ettiği pozitif aile ortalaması J ampirik bir gözlemdir; dış bir referansın dayanıklılık (robustness) için gerekli ya da yeterli olduğunu göstermez.

V. DENEY PROTOKOLÜ

A. Veri, eğitim ve kapsam

Tablo II veri kümelerini [33], [34], [35], [36], modelleri ve eğitim ayarlarını özetler. İstemci verileri Dirichlet bölümlemesini izler [37]; en az örnek sayısını güvenceye alan bir onarım her istemciye en az 20 örnek verir. MNIST, Fashion-MNIST ve UCI HAR 17 koşullu ortak bir ana bloğu paylaşır; CIFAR-10'un kapsamı daha dardır. Arşivlenmiş değerlendirme 149 iş ve 2 130 planlı kural-köşül-tohum biriminden oluşur (Tablo I); bunların 2 125'i tamamlanmıştır. Beş başarısızlık, yani dört örnek ağırlıklı HAR koşumu ve Min-Max altındaki bir CIFAR FLAME koşumu, hesapta tutulmuş; ne doldurulmuş ne de yenisiyle değiştirilmiştir.

B. Kontrol blokları ve saldırılar

Saldırgansız ana koşullar üç yoğunlaşma değerinin her birinde sıfır kötü niyetli istemciyle yapılandırılmıştır; CIFAR için $\alpha = 0.5$ kontrol hücresi yoktur. Yama arka kapısı karşılaştırması için saldırısı kapatılmış kontroller, saldırılı yapılandırmaların istemci kimliklerini ve çizelgelerini korur ve yalnızca saldırıyı kapatır.


Beş saldırı ailesi şunlardır: yüksek Gauss gürültüsü (koordinat başına standart sapma 5), etiket çevirme, sağ alt köşede 3×3 beyaz yama arka kapısı (hedef sınıf 0, zehirleme oranı 0.2), sınırlı rastgele bozulmalar ve kısıtlı her şeyi bilen yoklamalar. Sınırlı aile, 0.005 görelî ölçekte bir yön yoklamasını ve 0.3 görelî ölçekte rastgele gürültüyü içerir; ikincisi kodda eski `adaptive_gaussian` adını taşır, ancak eniyilenmiş bir uyarlanabilir saldırı değildir. Kısıtlı yoklamalar, dürüst ortalamanın tersi yönünde, Min-Max veya Min-Sum sınırını sağlayacak biçimde ölçeklenmiş ortak bir vektör gönderir [10].

C. Uygulamalar

Panel düz ortalama, örnek ağırlıklı ortalama, norm kırpmı, koordinat bazında medyan, $f = \lceil 0.3n \rceil$ ve $m = n - f - 2$ ile Multi-Krum, 100 kök örnekle normalize FLTrust, 0.001 gürültü düzeyli yerel HDBSCAN tabanlı bir FLAME ve Fed-MDBSCAN-G ile yedi ablasyon varyantından oluşur. Yerel FLTrust kuralını, yazarların gösterim kodundaki kuralın bir aktarımıyla 18 kayıtlı matris üzerinde karşılaştırdık; görelî fark 2.8×10^{-7} 'nin altında kaldı. FLAME'in kırpmı, ortalama alma ve gürültü ölçekleme adımları da sunucunun birleştirme yolu üzerinden sınıandı. Tamamlanmış 200 FLAME koşumunun hepsinde (6 000 tur) kaydedilmiş kabul kimliklerini saydık; Bölüm VI'da kullanılan tutulan küme boyutları bu sayımdan gelir. Bu denetimlerin kapsamı ek belgede ayrıntılı olarak verilmiş, Bölüm X'de özetlenmiştir.

D. Ölçütler

Dürüst fayda kaybı, aynı saldırgansız koşulda düz ortalamının son doğruluğu eksi savunmanın son doğruluğudur; saldırı altında fayda, savunmanın doğruluğu eksi düz ortalamının doğruluğudur. Doğruluk karşılaştırmaları her hücrenin tamamlanmış tohumlarını kullanır. Ayrıca saldırgan yakalama oranını, dürüst ret oranını, J değerini ve tetiklenmiş hedef dışı örneklerdeki saldırı başarı oranını (ASR) raporluyoruz.



Şekil 2. Mevcut veri kümesi hücreleri üzerinden ortalananmış saldırgansız dışlama. Kapsam yoğunlaşma değerine ve yöntemine göre değişir. FLTrust sıfır ağırlıklı gönderimleri sayar. FLAME sınırına her turda ulaşılması gerekmez; doğrudan boyutlar Tablo V içindedir.

FLTrust güveni pozitif olmayan gönderimlere sıfır ağırlık verir; BER, FPR ve TPR değerleri bu sıfır ağırlık kararlarını sayar. Alarm özgüllüğü yalnızca bileşik yöntem için raporlanır; paneldeki kurallar içinde tur düzeyinde alarm üreten tek yöntem odur.

VI. SALDIRGANSIZ DIŞLAMA VE FAYDA

Hiç saldırgan yokken bile ret yapan kurallar birçok koşulda dürüst gönderimlerin büyük bir kısmını dışlar (Tablo III, Şekil 2). Multi-Krum, mevcut dokuz hücrenin hepsinde, Sonuç 1'in gerektirdiği gibi tam olarak %32.22 dışlar.

FLAME'in temiz dışlamasını veri değil, küme boyutu kuralı belirler. Temiz turların çoğunda izin verilen en küçük çoğunluğu, yani 90 güncellenmenin tam 46'sını tutar (990 turun 719'u; Tablo V); bu yüzden dışlaması %42.4 ile %48.9 arasında kalır. Güçlü heterojenlik altında, en belirgin olarak HAR'da, daha büyük kümeler tutar ve sınıra daha seyrek ulaşır.

Fed-MDBSCAN-G farklı davranır. Dışlaması $\alpha = 0.5$ 'te %2.1'in altında kalır, ancak $\alpha = 0.01$ 'de %42.6'ya ulaşır (Tablo III); çünkü Aşama-1 eşiği her turun medyan yarıçapıyla ölçeklenir ve kabul edilen oran bu dağılımın biçimini izler.

Dışlama fayda kaybının yalnızca bir kaynağıdır (Tablo IV). Koordinat bazında medyan hiçbir istemciyi reddetmez, yine de MNIST'te $\alpha = 0.01$ koşulunda son doğruluğu düz ortalamasının 64.4 yüzde puan altındadır; en büyük kayıp olan 65.55 puan, aynı koşulda FLAME'e aittir. Raporlanan hücreler üzerinden ortalandığında kayıp, $\alpha = 0.5$ 'ten 0.01 'e düştükçe 3.3'ten 27.5 puana çıkar; bu yüzden kabul oranları tek başına dürüst faydayı değerlendirmeye yetmez.

Bileşik yöntemin tur düzeyindeki alarmı güçlü heterojenlik altında düşük özgüllüğe sahiptir (Tablo VI): $\alpha = 0.01$ 'de her veri kümesindeki her saldırgansız turda, $\alpha = 0.1$ 'de ise HAR turlarının neredeyse hepsinde alarm üretir. Bu alarmların hepsi yanlışdır.

Tablo III
SALDIRGANSIZ DÜRÜST İSTEMCİ DIŞLAMA ORANI (BER, %)

Kural	$\alpha = 0.5$			$\alpha = 0.1$				$\alpha = 0.01$			
	MNIST	Fashion	HAR	MNIST	Fashion	HAR	CIFAR-10	MNIST	Fashion	HAR	CIFAR-10
Düz ortalama (savunmasız)	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
Örnek ağırlıklı ortalama (savunmasız)	0.0	0.0	0.0	0.0	0.0	0.0	–	0.0	0.0	0.0	–
Norm kırma	0.0	0.0	0.0	0.0	0.0	0.0	–	0.0	0.0	0.0	–
Koordinat bazında medyan	0.0	0.0	0.0	0.0	0.0	0.0	–	0.0	0.0	0.0	–
Multi-Krum	32.2	32.2	32.2	32.2	32.2	32.2	–	32.2	32.2	32.2	–
FLTrust (normalize)	33.1	31.9	11.9	25.3	27.3	19.6	–	30.3	32.3	31.0	–
FLAME (HDBSCAN)	48.9	48.9	48.3	48.9	48.7	47.4	48.7	48.7	47.0	42.4	45.5
Fed-MDBSCAN-G (tam)	0.3	0.4	2.1	0.2	0.5	24.1	0.1	42.6	38.7	24.4	39.9

Hiç saldırgan yokken reddedilen dürüst istemci–tur gönderimleri; üç tohum, 30 tur ve turda 90 katılımcı (hücre başına 8 100 dürüst istemci–tur). Fashion, Fashion-MNIST anlamına gelir; tireler planlanan kapsam dışındaki koşullardır. FLTrust sıfır ağırlıklı gönderimleri sayar. Norm kırma ve koordinat bazında medyan hiçbir istemciyi reddetmez; bu yüzden BER değerleri tanım gereği sıfırdır ve dürüst maliyetleri Tablo IV içinde görülür.

Tablo IV
SALDIRGANSIZ DÜRÜST FAYDA KAYBI (BUC, YÜZDE PUAN)

Kural	$\alpha = 0.5$			$\alpha = 0.1$				$\alpha = 0.01$			
	MNIST	Fashion	HAR	MNIST	Fashion	HAR	CIFAR-10	MNIST	Fashion	HAR	CIFAR-10
Norm kırma	0.0	0.0	+0.2	0.0	0.0	+2.2	–	+22.5	+13.3	0.0	–
Koordinat bazında medyan	+0.6	+0.8	+9.8	+4.7	+5.1	+33.3	–	+64.4	+40.9	+23.8	–
Multi-Krum	+1.0	+1.3	+2.8	+4.6	+4.8	+29.2	–	+44.9	+33.6	+11.0	–
FLTrust (normalize)	+2.4	+2.5	+13.2	+3.3	+4.1	+29.2	–	+11.6	+5.1	+10.6	–
FLAME (HDBSCAN)	+1.7	+1.9	+19.6	+10.4	+6.7	+38.1	+15.5	+65.5	+45.9	+15.2	+15.6
Fed-MDBSCAN-G (tam)	0.0	0.0	+1.8	0.0	+0.1	+26.8	0.0	+59.2	+41.9	+10.4	+14.9

Savunmasız düz ortalamanın son tur doğruluğu eksi savunmanın; Tablo III ile aynı koşullar. Pozitif değerler düz ortalama dan daha düşük doğruluğu gösterir. Üç tohum üzerinden ortalamalar; tohum başına aralıklar ek belgede verilmiştir.

Tablo V
SALDIRGANSIZ KOŞULLARDA FLAME'İN TUTTUĞU KÜME BOYUTLARI

Veri kümesi	α	Ort. boyut	Aralık	Boyut 46
MNIST	0.5	46.01	46–47	89/90
MNIST	0.1	46.03	46–47	87/90
MNIST	0.01	46.17	46–49	77/90
Fashion	0.5	46.01	46–47	89/90
Fashion	0.1	46.19	46–50	81/90
Fashion	0.01	47.73	46–56	39/90
HAR	0.5	46.50	46–53	67/90
HAR	0.1	47.30	46–51	38/90
HAR	0.01	51.83	46–62	9/90
CIFAR-10	0.1	46.13	46–48	79/90
CIFAR-10	0.01	49.09	46–61	64/90

Saldırganız ana hücrelerde kaydedilmiş kabul kimliklerinden sayılmıştır; her satır üç tohum ve 90 tur kapsar. Boyut 46, izin verilen en küçük boyuttur: $\lfloor n/2 \rfloor + 1$.

Tablo VI
FED-MDBSCAN-G'NİN SALDIRGANSIZ TUR DÜZEYİ ALARM ORANI

α	Veri kümesi	Alarm veren tur	Oran (%)	BER (%)
0.5	MNIST	0/90	0.0	0.27
0.5	Fashion	0/90	0.0	0.41
0.5	HAR	19/90	21.1	2.07
0.1	MNIST	0/90	0.0	0.19
0.1	Fashion	0/90	0.0	0.53
0.1	HAR	89/90	98.9	24.06
0.1	CIFAR-10	0/90	0.0	0.12
0.01	MNIST	90/90	100.0	42.57
0.01	Fashion	90/90	100.0	38.69
0.01	HAR	90/90	100.0	24.37
0.01	CIFAR-10	90/90	100.0	39.94

Payda saldırganız turlardır; dolayısıyla her alarm yanlıştır. Değerlendirilen kurallar içinde tur düzeyinde alarm üreten tek kural Fed-MDBSCAN-G'dir; diğer kurallarda alarm kanalı yoktur ve onlar için oran verilmemiştir.

VII. SALDIRI ALTINDA AYIRT ETME

Saldırıları ayırt etme başarımı büyük ölçüde saldırı ailesine bağlıdır (Tablo VII; kural bazında Tablo VIII). Ret yapan dört kural üzerinden ortalığında J , yüksek Gauss gürültüsünde +68.6 puandan başlayıp etiket çevirmeden geçerek yama arka kapıları ve sınırlı bozulmalarda sıfıra yakın değerlere iner, kısıtlı yoklamalarda ise negatif olur (–16.1). Aileler saldırgan oranı, yoğunlaşma ve veri kümesi kapsamı bakımından da farklı olduğundan bu sıralama betimseldir.

Kısıtlı yoklamalar altında Multi-Krum yalnızca dürüst istemcileri reddeder (Tablo IX). Altı hücresinin beşinde 2 610 retin hepsi dürüsttür; bu da Sonuç 1'in sıfır saldırgan yakalamada öngördüğü $FPR = 29/63 = 46.03\%$ değerini

verir. İstisna, saldırgan yakalamanın pozitif olduğu HAR, $\alpha = 0.1$ hücresidir ($J = +36.68$ puan). Kısıtlı saldırganların hepsi aynı vektörü gönderdiğinden sıfır yakalama, seçim sınırındaki eşitliklerin nasıl bozulduğundan da kaynaklanabilir; dolayısıyla bu sayımlar Teorem 1'in sıralama öncülünü tek başına kanıtlamaz.

FLAME de benzer davranır. Sekiz kısıtlı yoklama hücresinin altısında saldırgan yakalaması sıfırdır ve FPR %57.51 ile %68.11 arasındadır; bu değerler, hiçbir saldırgan reddedilmediğinde tutulan çoğunluğun getirdiği $44/63 = 69.84\%$ tavanının altındadır. Fed-MDBSCAN-G de bu hücrelerin birçoğunda düşük veya sıfır saldırgan yakalamasına sahiptir.

FLTrust, kısıtlı ailede pozitif ortalama J elde eden tek

Tablo VII
SALDIRI AİLESİNE GÖRE İSTEMCİ DÜZEYİNDE AYIRT ETME

Saldırgan ailesi	Hücre	TPR (%)	FPR (%)	J (yp)	Fayda (yp)
Yüksek Gauss gürültüsü ($\sigma = 5$)	60	87.5	18.9	+68.6	+13.7
Etiket çevirme	36	69.7	24.8	+45.0	-9.0
Yama arka kapısı	16	34.0	32.3	+1.8	-19.2
Sınırlı rastgele yön	72	34.1	33.7	+0.4	-23.0
Kısıtlı her şeyi bilen	28	21.8	38.0	-16.1	-10.6

$J = \text{TPR} - \text{FPR}$ (Youden indeksi); $J < 0$ dürüst istemcilerin saldırılarından önce reddedildiğini gösterir. Fayda, aynı koşulda savunmanın doğruluğu eksi savunmasız doğruluktur. Her satır, ret yapan dört kuralın $\text{kural} \times \text{veri kümesi} \times \text{koşul}$ hücrelerini birleştirir; ailelerin kapsamı farklı olduğundan satırlar betimsel ortalamalardır.

Tablo VIII
KURALA VE SALDIRI AİLESİNE GÖRE AYIRT ETME

Saldırı ailesi / kural	Hücre	TPR (%)	FPR (%)	J (yp)	Fayda (yp)
<i>Yüksek Gauss gürültüsü ($\sigma = 5$)</i>					
Multi-Krum	15	100.0	10.4	+89.6	+16.5
FLTrust (normalize)	15	50.0	28.0	+22.0	+14.9
FLAME (HDBSCAN)	15	100.0	31.5	+68.5	+6.2
Fed-MDBSCAN-G (tam)	15	100.0	5.8	+94.2	+17.1
<i>Etiket çevirme</i>					
Multi-Krum	9	69.1	22.4	+46.7	-9.5
FLTrust (normalize)	9	79.0	26.7	+52.3	-4.7
FLAME (HDBSCAN)	9	78.5	38.8	+39.7	-14.0
Fed-MDBSCAN-G (tam)	9	52.3	11.1	+41.2	-7.9
<i>Yama arka kapısı</i>					
FLTrust (normalize)	4	31.4	27.6	+3.8	-7.9
FLAME (HDBSCAN)	6	48.4	47.5	+0.9	-26.7
Fed-MDBSCAN-G (tam)	6	21.4	20.2	+1.2	-19.2
<i>Sınırlı rastgele yön</i>					
Multi-Krum	18	33.7	31.7	+2.1	-23.2
FLTrust (normalize)	18	29.7	29.8	-0.1	-9.3
FLAME (HDBSCAN)	18	47.5	46.7	+0.9	-33.0
Fed-MDBSCAN-G (tam)	18	25.3	26.7	-1.4	-26.3
<i>Kısıtlı her şeyi bilen</i>					
Multi-Krum	6	9.7	41.9	-32.2	-20.1
FLTrust (normalize)	6	66.3	30.7	+35.6	+14.1
FLAME (HDBSCAN)	8	13.1	57.9	-44.7	-19.6
Fed-MDBSCAN-G (tam)	8	6.4	20.6	-14.2	-12.9

Mevcut hücreler üzerinden ortalamalar; sütunlar Tablo VII ile aynıdır. FLTrust sıfır ağırlık kararlarını sayar.

kuraldır (+35.6 puan); bu, güvenilir veri sinyallerini ileride incelenmeye değer bir yön olarak gösterir. FLTrust temiz turlarda dürüst gönderimlerin %11.9–33.1'ine de sıfır ağırlık verir (Tablo III).

Düşük saldırı başarısı tek başına koruma anlamına gelmez (Tablo X). $\alpha = 0.1$ 'de bileşik yöntem kontrole yakın doğruluğu korur, ancak arka kapı üç veri kümesinin hepsinde tetiklenmiş örneklerin %96'sından fazlasında başarılı olur. $\alpha = 0.01$ 'de saldırı başarısı daha düşüktür, ancak ana görev doğruluğu en fazla %32.8'dir ve zehirlenmemiş kontrol bile yamalı CIFAR örneklerinin %20.8'ine hedef etiketi atar. Bu nedenle doğruluk, saldırılı ASR ve kontrol ASR birlikte okunmalıdır.

VIII. KARAR YOLU ANALİZİ

Bu bölüm, Aşama 1'in üzerindeki aşamaların neden bu kadar az şey değiştirdiğini soruyor. Üç gözlem bu soruyu

Tablo IX
KISITLI HER ŞEYİ BİLEN SALDIRGAN ALTINDA ÇALIŞMA NOKTALARI

Veri kümesi	Kural	TPR (%)	FPR (%)	J (yp)	Öngörülen FPR (%)
$\alpha = 0.1$					
MNIST	Multi-Krum	0.00	46.03	-46.03	46.03
MNIST	FLAME (HDBSCAN)	0.00	68.11	-68.11	≤ 69.84
Fashion	Multi-Krum	0.00	46.03	-46.03	46.03
Fashion	FLAME (HDBSCAN)	0.00	65.59	-65.59	≤ 69.84
HAR	Multi-Krum	57.90	21.22	+36.68	46.03
HAR	FLAME (HDBSCAN)	96.67	27.25	+69.42	≤ 69.84
CIFAR-10	FLAME (HDBSCAN)	8.33	62.94	-54.60	≤ 69.84
$\alpha = 0.01$					
MNIST	Multi-Krum	0.00	46.03	-46.03	46.03
MNIST	FLAME (HDBSCAN)	0.00	58.82	-58.82	≤ 69.84
Fashion	Multi-Krum	0.00	46.03	-46.03	46.03
Fashion	FLAME (HDBSCAN)	0.00	63.19	-63.19	≤ 69.84
HAR	Multi-Krum	0.00	46.03	-46.03	46.03
HAR	FLAME (HDBSCAN)	0.00	59.47	-59.47	≤ 69.84
CIFAR-10	FLAME (HDBSCAN)	0.00	57.51	-57.51	≤ 69.84

Yüzde otuz saldırı: turda 63 dürüst ve 27 saldırı katılımcı. Öngörülen FPR, sıfır saldırı yakalamadaki ($\text{TPR} = 0$) değerdir: Multi-Krum için bir özdeşlik, FLAME için bir üst sınır (Sonuç 1–2). FLTrust ve Fed-MDBSCAN-G böyle bir öngörü vermez; bu kurallar Tablo VIII içindedir. CIFAR-10/FLAME/ $\alpha = 0.1$ (iki tamamlanmış tohumdan 60 tur) dışında her hücrede 90 kayıtlı tur vardır.

Tablo X
FED-MDBSCAN-G'NİN YAMA ARKA KAPISI SONUÇLARI VE EŞLEŞEN KONTROLLER

α	Veri kümesi	Saldırılı		Saldırı kapalı	
		Doğr. (%)	ASR (%)	Doğr. (%)	ASR (%)
0.1	MNIST	93.97	99.99	94.14	0.57
0.1	Fashion	83.34	99.93	83.42	2.63
0.1	CIFAR-10	49.55	96.59	49.85	5.76
0.01	MNIST	28.20	79.85	26.01	5.52
0.01	Fashion	32.83	56.18	32.24	1.85
0.01	CIFAR-10	15.47	26.86	15.83	20.80

ASR, tetiklenmiş hedef dışı örneklerdeki saldırı başarı oranıdır. Doğruluk ve ASR birlikte verilmiştir; düşük doğruluklu $\alpha = 0.01$ bloğu etkili koruma olarak okunmamalıdır.

yanıtlar. Küme aşaması nadiren çalışır; kullanılan kapı altında 36 saldırılı kontrol noktasının hiçbirinde çalışmaz. Çalışmaya zorlandığında, Önerme 3'ün yeter koşulu bu 36 kontrol noktasının 35'inde sağlanır; yani aşama hiçbir grubu reddedemez. Testi, test etmeden bıraktığı güncellemelere genişletmek dürüst ret ekler, ancak saldırıyı reddi eklemeyiz.

Yeniden oynatma, MNIST ve Fashion-MNIST'ten alınmış 72 kayıtlı güncelleme matrisini 18'erlik dört blokta kullanır: Min-Max ve yama saldırıları ile her birinin saldırısı kapatılmış kontrolü. Saldırılı matrisler 90 katılımcı arasında 18 saldırı içerir. Her matris iki kapı ayarı ve iki komşuluk kesmesi seçeneği altında değerlendirilir.

A. Kapının çalışması ve ölçülen yarıçap koşulu

Kullanılan kapı altında küme aşaması 72 kontrol noktasının 10'unda çalışır, 36 saldırılı kontrol noktasının hiçbirinde çalışmaz. Destekleyici Aşama-1 retleri koşulunu kaldırmak, yani yalnız yoğunluk kapısı, 144 karşılaştırmanın hepsinde kabul kümesini değiştirmez.

Tablo XI

SALDIRILI KONTROL NOKTALARINDA İLK KABUL HAVUZUNUN RADYAL ORANI

Saldırı	Matris	$\Gamma \leq 2$	Medyan	En büyük
Min-Max	18	18	1.257	1.622
Yama	18	17	1.666	2.017
Tüm saldırılı	36	35	1.448	2.017

Farklı saldırılı kontrol noktası matrisleri; eşik $\tau = 2$ değeridir. İki kapı değerlendirmesi aynı matrisi kullandığından her matris bir kez sayılmıştır. 36 matrisin hepsinde B_0 90 katılımcının tamamını içerir. İstisna Fashion, tohum 137, yama, tur 29'dur.

Tablo XII

72 KAYITLI GÜNCELLEME MATRİSİNDE UZLAŞMA TESTİ KAPSAMININ YENİDEN OYNATILMASI

Kapı	Saldırı	P0	P1	P2
<i>Saldırılı matrisler</i>				
Kullanılan kapı	Min-Max	0/0	0/0	0/0
Kullanılan kapı	Yama	0/0	0/0	0/0
Yalnız yoğunluk	Min-Max	0/0	0/0	0/0
Yalnız yoğunluk	Yama	0/0	1/0	142/46
<i>Saldırısı kapatılmış kontroller</i>				
Kullanılan kapı	Min-Max	319/0	351/0	326/0
Yalnız yoğunluk	Min-Max	319/0	395/0	404/0
Kullanılan kapı	Yama	1/0	1/0	1/0
Yalnız yoğunluk	Yama	1/0	1/0	82/0

Küme yapısı, geometri ve etkinleşme belleği sabit tutulmuştur. Değerler, emniyet valfinden sonraki istemci-kontrol noktası sayısı olarak dürüst/saldırgan retleridir. P0 kullanılan politikadır (yalnız kümeler); P1 kümelenmemiş düşük yoğunluklu güncellemeleri ayrıca tekil olarak aynı teste sokar; P2 bunları doğrudan dışlar. Her saldırılı blok 1 296 dürüst ve 324 saldırırgan gözlemi, her saldırısı kapatılmış blok 1 620 dürüst gözlemi içerir.

Tablo XI, (2) içindeki tabanlanmış yarıçapla hesaplanan radyal oran $\Gamma(B_0)$ 'ı verir. Her saldırılı matriste B_0 90 güncellenmenin hepsini içerir; dolayısıyla her aday grup B_0 'ın içindedir. Yeter koşul **36 saldırılı matrisin 35'inde** sağlanır: 18 Min-Max matrisinin hepsinde ve 18 yama matrisinin 17'sinde. Bu matrislerde B_0 üyelerini yeniden gruplamak bir merkezi $2R_0$ yarıçapının dışına taşıyamaz; bu yüzden kapı açılabilir bile uzlaşma testi hiçbir grubu reddetmez. Kalan matriste koşul sağlanmaz, ancak bulunan gruplar yine de kabul edilir. Koşul yalnızca bu saldırılı kontrol noktalarını güvenceye alır; bu bloğun dışında bazı aday grupların B_0 dışında üyeleri vardır (ek belge).

B. Yönlendirme ve doğrulama farklı olaylardır

Kapıyı açmak, yama saldırırganlarının uzlaşma testine ulaşmasını sağlar, ancak saldırırganlar testi geçer. Yalnız yoğunluk kapısı altında yama işlemesi 18 saldırılı kontrol noktasının 17'sinde açılır. Komşuluk kesmesi etkinken 306 saldırırgan gözlemin 239'u bulunan gruplara girer ve 55 grubun 30'u saldırırgan içerir; yine de bu grupların hiçbirisi reddedilmez. Kısıtlı yoklamada da kayıtlı yönlendirme reddedilmiş bir saldırırgan grubu üretmez. Uygulama, birebir kopya güncellemelere keyfi biçimde yüksek bir değer yerine yoğunluk 1 atar; bu yüzden Önerme 4 kopyalanmış vektör saldırısını açıklamaz.

Tablo XIII

SALDIRGANSIZ BİR MNIST KONTROL NOKTASINDA BULUNAN KÜMELER

Kol	Küme	Boyut	B_0 içinde	Oran	Karar
A	0	38	38	0.13	kabul
A	1	6	6	1.84	ret
A	2	6	0	2.38	ret
A	3	4	4	1.90	ret
A	4	4	0	2.63	ret
A	5	4	4	1.99	ret
B	0	37	37	0.13	kabul
B	1	6	6	1.70	ret
B	2	4	4	1.87	ret
C	0	34	34	0.12	kabul
C	1	4	4	1.72	ret

Tohum 2024, tur 9; bütün istemciler dürüştür. Mini-batch rejimleri: A, 32 örneklik standart yükleyici; B, her yerel adımda yeni bir 20 örneklik altküme; C, ilk 20 örneklik mini-batch'in beş kez tekrarı. Oran, $\tau = 2$ ve R_0 (2) ile tanımlı olmak üzere $\|c_S - m_{B_0}\|/(\tau R_0)$ değeridir; oran 1'i aşınca grup reddedilir.

Tablo XIV

UÇ NOKTA ABLASYONLARI: VARYANT İLE TAM YÖNTEM ARASINDAKİ SON DOĞRULUK FARKI (YÜZDE PUAN)

Varyant	Hücre	Ort.	En az	En çok
Fed-MDBSCAN-G, yalnız 1. aşama	12	-0.081	-1.50	+0.84
Geometrik medyan uzaklık kontrolü	12	-0.081	-1.50	+0.84
Fed-MDBSCAN-G, etkinleşme belleği yok	12	0.000	0.00	0.00
Fed-MDBSCAN-G, valf yok	12	+0.278	-0.27	+3.03
Güven bölgesi çarpanı 1.5	12	-0.916	-8.42	+2.90
Güven bölgesi çarpanı 2.0	12	-0.860	-3.09	+2.95
Güven bölgesi çarpanı 3.0	12	+0.575	-6.38	+12.82

Varyant eksi tam bileşik yöntem, yüzde puan cinsinden son doğruluk farkı; hücreler eşleşen ablasyon bloğunda üç tohum üzerinden veri kümesi $\times$ koşul ortalamalarıdır. Aralıklar koşullar arasındaki değişkenliği gösterir, güven aralığı değildir.

C. Kümelenmemiş güncellemeler üzerinde müdahaleler

Daha fazla güncellemeyi test etmek saldırırgan değil dürüst ret ekler (Tablo XII). Geometri, geçmiş ve grup üyeliği sabit tutularak, yalnızca bulunan grupları test eden kullanılan politika (P0), kümelenmemiş düşük yoğunluklu güncellemeleri tekil olarak test etmekle (P1) ve onları doğrudan dışlamakla (P2) karşılaştırılır. P1 iki kapı altında da saldırırgan reddi eklemeyiz; ancak kullanılan kapı altında 32, yalnız yoğunluk kapısı altında 77 dürüst ret ekler. Tek olumlu ödünleşimi P2, yalnız yoğunluk kapısındaki yama bloğunda verir ($J = +3.24$ puan); bunun bedeli eşleşen kontrolde 82 dürüst rettir.

Temiz bir MNIST kontrol noktası bunun tersini gösterir: aynı test dürüst azınlık gruplarını reddeder (Tablo XIII). Kontrol noktası, beş sabit yerel adımla $\alpha = 0.01$ 'de yapılmış ayrı bir koşturmadan alınmış ve üç mini-batch rejimi altında yeniden oynatılmıştır. Her rejimde en büyük grup ret yarıçapının 0.12–0.13 katı, her küçük grup ise 1.70–2.63 katı uzaklıktadır; bu yüzden bütün katılımcılar dürüst olduğu hâlde küçük grupların hepsi reddedilir. Son ret sayısı A rejimindeki 34'ten C rejiminde 18'e düşer; bunun temel nedeni test edilen bir gruba daha az istemcinin girmesidir. Yeni kabul edilen istemcilerin hiçbirisi grubu testi geçtiği için kabul edilmemiştir.

D. Uç nokta ablasyonları

Aşama 1'in üzerindeki bütün aşamaları kaldırmak son doğruluğu neredeyse değiştirmez (Tablo XIV). 12 eşleşen veri kümesi–koşul hücresi ve 36 uç nokta koşumu üzerinden, yalnız 1. aşama varyantı tam bileşik yöntemden ortalamada -0.081 yüzde puan farklıdır; valfi kaldırmak ortalamayı $+0.278$ puan değiştirir, etkinleşme belleği olmayan varyant ise 36 uç noktanın hepsiyle aynıdır.

IX. TARTIŞMA

Saldırgan yokken dürüst istemcilere düşen maliyet birçok yapılandırmada büyüktür. Sabit kardinaliteli seçimde bu maliyeti seçilen sayı belirler; küme tutma bir sınır getirir ve doğrudan sayımlar bu sınıra ne sıklıkla ulaşıldığını gösterir. Hiçbir dışlama ölçütü fayda ölçümünün yerini tutmaz: birleştirme hiçbir istemciyi reddetmeden doğruluğu düşürebilir ve bir model doğruluğunu korurken bir arka kapıyı öğrenebilir.

Fed-MDBSCAN-G için ölçülen yarıçap koşulu somut bir tasarım dersi verir. Her aday grup, en büyük yarıçapı merkez testi eşliğinin altında kalan bir kabul havuzunun içindeyse, hiçbir yeniden gruplama testin bir grubu reddetmesini sağlayamaz. Bu yüzden kümeleme karmaşıklığı eklenmeden önce geometrik kapsam denetlenmelidir; farklı bir grup istatistiği, referans noktası veya eşik farklı davranabilir.

Yararlı bir değerlendirme; hedeflenen heterojenlik düzeylerinde temiz dışlamayı ve faydayı, kesin kabul ve geri dönüş kurallarını, eşleşen kontrollerle birlikte saldırı tarafındaki TPR, FPR, doğruluk ve ASR değerlerini raporlamalıdır. Birlikte raporlandıklarında bu nicelikler, herhangi birinin tek başına gizleyebileceği başarısızlıkları ortaya çıkarır. Tek bir turdaki dışlama bir katılım kararıdır; kalıcı istemci çıkarılması ya da modele verilen zararın doğrudan ölçüsü değildir.

X. SINIRLILIKLAR

Kanıtın kapsamı. Sonuçlar üç tohuma, 30 turluk ufuklara, küçük modellere ve dengesiz bir kapsama dayanır; bölümlenme onarımı da örneklenen heterojenliği değiştirir. İstemci–turlar bağımsız tekrarlar değil, birbiriyle ilişkili gözlemlerdir; bu nedenle bütün sonuçlar betimseldir ve hiçbir savunma için istatistiksel anlamlılık, eşdeğerlik veya genel üstünlük iddia etmiyoruz. Saldırı aileleri kapsamlı bir arama değil, belirlenmiş yapılarıdır ve adları ölçülmüş bir yer değiştirmeyi ifade etmez.

Uygulama sadakati. Karşılaştırılan yöntemler yerel uygulamalardır. FLTrust denetimi birleştirme kuralını kapsar, ancak dejenere kök yollarını ve tam eğitim protokolünü kapsamaz; FLAME'in kümelemesi ve gürültü ayarı yazarların uygulamasına karşı doğrulanmamıştır. Bir kardinalite özdeşliğiyle uyum, kuralın doğru sayıda güncelleme tuttuğunu gösterir; özgün uygulamayla aynı güncellemeleri tuttuğunu göstermez. Ayrıntılar ek belgededir.

Geriye dönük analiz. Bölüm IV'teki koşullu argümanlar ve kontrol noktası analizleri sonuçlar incelendikten sonra geliştirilmiştir; içerik özetleri (hash) kanıt dosyalarını tanımlar, ancak ön kayıt (preregistration) anlamına gelmez. Yeniden oynatmalar kayıtlı gidişatları kullanır, oysa değiştirilmiş bir savunma sonraki girdileri de değiştirdi; CIFAR tekrarlanabilirliği de tek bir tanı koşulu için gösterilmiştir. Bu temel özdeşlikler bu nedenle değerlendirilen karar yollarını

açıklar; genel imkânsızlık teoremleri değildir. Güvenilir ve rinin, zamansal bilginin, alternatif güncelleme gösterimleri nin veya istemci tarafı doğrulanmanın bu sonuçları değiştirip değiştirmeyeceği açık bir sorudur.

XI. SONUÇ

Saldırganız dışlamayı ve saldırı altındaki kararları, 2125 tamamlanmış koşum ve beş kayıtlı başarısızlık içeren bir federe öğrenme değerlendirmesinde sekiz sonucu tarafı kuralın seçim davranışıyla ilişkilendirdik. Multi-Krum'un temiz dışlaması sabit kardinalitesinden kaynaklanır; doğrudan FLAME sayımları ise küme boyutu sınırına ne zaman ulaşıldığını gösterir. Fed-MDBSCAN-G için denetlenmiş alt-küme koşulu ve ölçülen yarıçap oranı, küme merkezi doğrulamasının 36 saldırılı kontrol noktası matrisinin 35'inde neden hiçbir aday grubu reddedemediğini açıklar; testi daha önce test edilmeyen güncellemelere genişletmek bu yeniden oynatmalarda saldırgan reddi eklemeyiz. Bu bulgular dürüst maliyetin, saldırı tespitin ve saldırı başarısının, uygulama sınırları ve koşullu argümanlar açıkça belirtilerek birlikte raporlanmasını destekler.

VERİ VE KOD ERIŞİLEBİLİRLİĞİ

Ek yapıt; hücre ve birim düzeyindeki sonuçları, başarısızlık muhasebesini, kontrol noktası özetlerini ve makaledeki tabloları ve şekilleri yeniden üreten betikleri içerir. Proje deposu <https://github.com/Bygokcen/fed-mdbscan-g> adresindedir. Ham eğitim çıktıları ve dondurulmuş kaynaklar yerel araştırma arşivinde tutulur ve depo klonuna dahil değildir. Sağlanan özetler raporlanan aritmetiğin denetlenmesine olanak tanır; geçmiş kimlik ve kontrol noktası denetimlerini yeniden üretmek için ise bu arşiv de gereklidir.

TEŞEKKÜR

Bu araştırma, kamu, ticari veya kâr amacı gütmeyen sektörlerdeki herhangi bir fon kuruluşundan özel bir destek almamıştır.

ÜRETKEN YAPAY ZEKÂ VE YAPAY ZEKÂ DESTEKLİ TEKNOLOJİLERİN KULLANIMINA İLİŞKİN BEYAN

Bu çalışmanın hazırlanması sırasında yazarlar, üretken yapay zekâ araçlarını dil düzenlemesi ve makale biçimlendirme desteği ile analiz kodunun geliştirilmesi ve denetlenmesi için kullanmıştır. Bütün deneysel sonuçlar arşivlenmiş koşum kayıtlarından ve analiz betiklerinden türetilmiştir. Yazarlar yapay zekâ ile üretilen bütün içeriği gözden geçirip düzenlemiş ve yayının içeriğine ilişkin bütün sorumluluğu üstlenmiştir.

YAZAR KATKILARI

S. G. Özden: yöntem, yazılım, doğrulama, biçimsel analiz, araştırma, veri düzenleme, görselleştirme, özgün taslağın yazımı. K. Sarıkaya: kavramsallaştırma, danışmanlık, gözden geçirme ve düzenleme.

ÇIKAR ÇATIŞMASI BEYANI

Yazarlar, bu makalede raporlanan çalışmayı etkilemiş gibi görünebilecek bilinen hiçbir finansal çıkar çatışması veya kişisel ilişkileri bulunmadığını beyan eder.

KAYNAKLAR

- [1] B. McMahan, E. Moore, D. Ramage, S. Hampson, and B. A. y Arcas, "Communication-efficient learning of deep networks from decentralized data," in *Proc. 20th Int. Conf. Artificial Intelligence and Statistics (AISTATS)*, ser. PMLR, vol. 54, 2017, pp. 1273–1282.
- [2] M. Fang, X. Cao, J. Jia, and N. Z. Gong, "Local model poisoning attacks to Byzantine-robust federated learning," in *Proc. 29th USENIX Security Symp.*, 2020, pp. 1623–1640.
- [3] E. Bagdasaryan, A. Veit, Y. Hua, D. Estrin, and V. Shmatikov, "How to backdoor federated learning," in *Proc. 23rd Int. Conf. Artificial Intelligence and Statistics (AISTATS)*, ser. PMLR, vol. 108, 2020, pp. 2938–2948.
- [4] C. Xie, K. Huang, P.-Y. Chen, and B. Li, "DBA: Distributed backdoor attacks against federated learning," in *Proc. 8th Int. Conf. Learning Representations (ICLR)*, 2020.
- [5] P. Blanchard, E. M. E. Mhamdi, R. Guerraoui, and J. Stainer, "Machine learning with adversaries: Byzantine tolerant gradient descent," in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 30, 2017, pp. 119–129.
- [6] D. Yin, Y. Chen, K. Ramchandran, and P. L. Bartlett, "Byzantine-robust distributed learning: Towards optimal statistical rates," in *Proc. 35th Int. Conf. Machine Learning (ICML)*, ser. PMLR, vol. 80, 2018, pp. 5650–5659.
- [7] X. Cao, M. Fang, J. Liu, and N. Z. Gong, "FLTrust: Byzantine-robust federated learning via trust bootstrapping," in *Proc. Network and Distributed System Security Symp. (NDSS)*, 2021.
- [8] T. D. Nguyen, P. Rieger, H. Chen, H. Yalame, H. Möllering, H. Fereidooni, S. Marchal, M. Miettinen, A. Mirhoseini, S. Zeitouni, F. Koushanfar, A.-R. Sadeghi, and T. Schneider, "FLAME: Taming backdoors in federated learning," in *Proc. 31st USENIX Security Symp.*, 2022, pp. 1415–1432.
- [9] G. Baruch, M. Baruch, and Y. Goldberg, "A little is enough: Circumventing defenses for distributed learning," in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 32, 2019, pp. 8632–8642.
- [10] V. Shejwalkar and A. Houmansadr, "Manipulating the Byzantine: Optimizing model poisoning attacks and defenses for federated learning," in *Proc. Network and Distributed System Security Symp. (NDSS)*, 2021.
- [11] A. K. Singh, A. Blanco-Justicia, and J. Domingo-Ferrer, "Fair detection of poisoning attacks in federated learning on non-i.i.d. data," *Data Mining and Knowledge Discovery*, vol. 37, no. 5, pp. 1998–2023, 2023.
- [12] P. Ye, Y. Li, K. He, Q. Li, T. Qin, X. Wang, K. Yang, C. Zhang, and J. Chen, "Breaking the illusion: A critical study of backdoor defense in federated learning with non-IID data," *IEEE Trans. Inf. Forensics Security*, vol. 20, pp. 13 264–13 279, 2025.
- [13] A. A. Bellachia, M. A. Bouchiha, and Y. Ghamri-Doudane, "SoK: Understanding backdoor attacks and defenses in federated learning," *Expert Systems with Applications*, vol. 325, p. 132558, 2026.
- [14] O. Touat and S. Bouchenak, "Towards robust and bias-free federated learning," in *Proc. 3rd Workshop on Machine Learning and Systems (EuroMLSys)*, 2023.
- [15] O. Ajibuwa and O. T. Odeyomi, "On the hidden costs of fairness in Byzantine-robust decentralized federated learning under data heterogeneity," in *Proc. IEEE Int. Performance, Computing, and Communications Conf. (IPCCC)*, 2025.
- [16] A. Djemaa, D. Djenouri, and P. Legg, "Heterogeneity-aware poisoning attacks and mitigation in federated learning: A comprehensive survey and taxonomy," *Electronics*, vol. 15, no. 13, p. 2876, 2026.
- [17] K. Pillutla, S. M. Kakade, and Z. Harchaoui, "Robust aggregation for federated learning," *IEEE Trans. Signal Process.*, vol. 70, pp. 1142–1154, 2022.
- [18] S. P. Karimireddy, L. He, and M. Jaggi, "Byzantine-robust learning on heterogeneous datasets via bucketing," in *Proc. 10th Int. Conf. Learning Representations (ICLR)*, 2022.
- [19] Y. Allouah, S. Farhadkhani, R. Guerraoui, N. Gupta, R. Pinot, and J. Stephan, "Fixing by mixing: A recipe for optimal Byzantine ML under heterogeneity," in *Proc. 26th Int. Conf. Artificial Intelligence and Statistics (AISTATS)*, ser. PMLR, vol. 206, 2023, pp. 1232–1300.
- [20] P. Rieger, T. D. Nguyen, M. Miettinen, and A.-R. Sadeghi, "DeepSight: Mitigating backdoor attacks in federated learning through deep model inspection," in *Proc. Network and Distributed System Security Symp. (NDSS)*, 2022.
- [21] E. Kabir, Z. Song, M. R. U. Rashid, and S. Mehnaz, "FLShield: A validation based federated learning framework to defend against poisoning attacks," in *Proc. IEEE Symposium on Security and Privacy (SP)*, 2024, pp. 2572–2590.
- [22] P. Rieger, T. Krauß, M. Miettinen, A. Dmitrienko, and A.-R. Sadeghi, "CrowdGuard: Federated backdoor detection in federated learning," in *Proc. Network and Distributed System Security Symp. (NDSS)*, 2024.
- [23] T. Krauß and A. Dmitrienko, "MESAS: Poisoning defense for federated learning resilient against adaptive attackers," in *Proc. 2023 ACM SIG-SAC Conf. Computer and Communications Security (CCS)*, 2023, pp. 1526–1540.
- [24] Z. Chen, F. Wang, Z. Zheng, X. Liu, and Y. Lin, "Fedward: Flexible federated backdoor defense framework with non-IID data," in *Proc. IEEE Int. Conf. Multimedia and Expo (ICME)*, Brisbane, Australia, 2023, pp. 348–353.
- [25] J. Yuan, Q. Zhang, N. Chen, S. Chen, and B. Xu, "A multi-granularity clustering approach for federated backdoor defense with the Adam optimizer," in *Proc. 34th Int. Joint Conf. Artificial Intelligence (IJCAI)*, 2025, pp. 6931–6939.
- [26] M. V. Ramana, C. Nagabharani, S. G. Krishna, V. V. Moresh, and A. Malathi, "Adaptive local density-based defense against poisoning attacks in federated learning," in *Proc. 5th Int. Conf. Computer Networks, Big Data and IoT (ICCB)*, Dubai, United Arab Emirates, 2026.
- [27] J. Qian, Y. Zhou, X. Han, and Y. Wang, "MDBSCAN: A multi-density DBSCAN based on relative density," *Neurocomputing*, vol. 576, p. 127329, 2024.
- [28] P. Viola and M. J. Jones, "Robust real-time face detection," *International Journal of Computer Vision*, vol. 57, no. 2, pp. 137–154, 2004.
- [29] M. Kloft and P. Laskov, "Security analysis of online centroid anomaly detection," *Journal of Machine Learning Research*, vol. 13, pp. 3681–3724, 2012.
- [30] Q. Li, D. Wu, D. Zhou, C. Lin, S. Liu, C. Wang, and C. Shen, "Robust adversarial defenses in federated learning: Exploring the impact of data heterogeneity," *IEEE Trans. Inf. Forensics Security*, vol. 20, pp. 6005–6018, 2025.
- [31] V. Shejwalkar, A. Houmansadr, P. Kairouz, and D. Ramage, "Back to the drawing board: A critical evaluation of poisoning attacks on production federated learning," in *Proc. IEEE Symp. Security and Privacy (S&P)*, 2022, pp. 1354–1371.
- [32] G. Abad, M. Krček, S. Koffas, B. Tajalli, M. Arazzi, R. Riaño, X. Xu, Z. Liu, A. Nocera, and S. Picck, "SoK: The last line of defense: On backdoor defense evaluation," *arXiv preprint arXiv:2511.13143*, 2025.
- [33] Y. LeCun, L. Bottou, Y. Bengio, and P. Haffner, "Gradient-based learning applied to document recognition," *Proceedings of the IEEE*, vol. 86, no. 11, pp. 2278–2324, 1998.
- [34] H. Xiao, K. Rasul, and R. Vollgraf, "Fashion-MNIST: A novel image dataset for benchmarking machine learning algorithms," *arXiv preprint arXiv:1708.07747*, 2017.
- [35] D. Anguita, A. Ghio, L. Oneto, X. Parra, and J. L. Reyes-Ortiz, "A public domain dataset for human activity recognition using smartphones," in *Proc. 21st European Symp. Artificial Neural Networks (ESANN)*, 2013, pp. 437–442.
- [36] A. Krizhevsky, "Learning multiple layers of features from tiny images," University of Toronto, Tech. Rep., 2009. [Online]. Available: <https://www.cs.toronto.edu/~kriz/learning-features-2009-TR.pdf>
- [37] T.-M. H. Hsu, H. Qi, and M. Brown, "Measuring the effects of non-identical data distribution for federated visual classification," *arXiv preprint arXiv:1909.06335*, 2019.